



UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea Magistrale in Informatica

Data Science & Machine Learning

TESI DI LAUREA

Un framework multimodale di analisi vocale automatica per la caratterizzazione del dolore in ambito clinico

RELATORE

Prof. Stefano Cirillo

CORRELATORI

Dr. Giandomenico Solimando

Dr. Raffaele Aurucci

CANDIDATO

Mariarosaria Rossi

Matricola: 0522501867

Anno Accademico 2025-2026

«Tutto è possibile»

Pino Daniele

A mio **padre**,
il mio angelo custode,
che mi accompagna da sempre,
anche da lassù.

A mio **nipote** Flavio,
nuova luce della nostra famiglia,
piccolo custode di quel bene prezioso
che ci leggerà per sempre.

Abstract

Il dolore è un fenomeno clinico complesso e multidimensionale, la cui valutazione dipende in larga misura da quanto riferito dal paziente. L'analisi automatica del parlato può offrire una fonte complementare di informazione. Tuttavia, la letteratura riguarda soprattutto campioni ridotti, dolore indotto e registrazioni controllate, mentre il parlato spontaneo prodotto durante interviste cliniche multi-parlante è ancora poco studiato.

Per affrontare questo limite, la tesi propone un framework computazionale applicato a 92 registrazioni relative a 90 pazienti. Dopo la speaker diarization e l'identificazione del paziente, vengono analizzate finestre temporali di durata controllata e interventi vocali reali. Da queste unità sono estratte caratteristiche acustiche, prosodiche e comportamentali, embedding audio Whisper-small e Wav2Vec2, embedding testuali MiniLM e una rappresentazione multimodale audio-testo. Gli esperimenti comprendono un'analisi di sensitività sulla segmentazione, clustering non supervisionato, regressione logistica, Random Forest, XGBoost e Multiple Instance Learning, con valutazione patient-level rispetto a DN4, NRS e BPI. Sono inoltre individuati e confrontati, controllandone la durata, 301 interventi vocali *pain-related*.

I risultati evidenziano cluster stabili, ma privi di associazioni robuste con gli score clinici. Gli embedding Whisper-small patient-level raggiungono una ROC-AUC di 0.5400, mentre XGBoost sulle caratteristiche interpretabili ottiene 0.6117, senza superare il permutation test. Il risultato più elevato è prodotto dalla baseline basata sulla durata, con ROC-AUC pari a 0.7134 e $p_{AUC} = 0.001$. Tale prestazione suggerisce che il modello sfrutti aspetti della dinamica temporale e conversazionale, più che un biomarcatore vocale autonomo del dolore.

Indice	i
Elenco delle figure	iii
Elenco delle tabelle	iv
1 Introduzione	1
2 Stato dell'arte	3
2.1 Valutazione clinica del dolore	3
2.2 Il parlato come fonte di biomarcatori digitali	4
2.3 Contributo della tesi	7
3 Background	10
3.1 Caratteristiche acustiche, prosodiche e temporali	10
3.2 Representation learning e Transformer	11
3.3 Modelli pre-addestrati per il parlato	12
3.4 Rappresentazioni testuali e multimodali	14
3.5 Riduzione dimensionale e clustering	15
3.6 Classificazione supervisionata	17
3.7 Multiple Instance Learning	18
4 Metodologia	20
4.1 Input clinico e audio	21

4.2	Diarizzazione e identificazione del paziente	22
4.3	Costruzione delle unità di analisi	23
4.4	Estrazione delle rappresentazioni	25
4.5	Analisi e interpretazione clinica	27
5	Risultati	34
5.1	Setup di valutazione	34
5.2	Risultati quantitativi	35
5.2.1	Analisi di sensitività e Whisper-small patient-level	35
5.2.2	Profilazione acustica e comportamentale	37
5.2.3	Associazione dei profili con DN4, NRS e BPI	39
5.2.4	Classificazione turn-level con Random Forest e XGBoost	41
5.2.5	Turni pain-related e confronto duration-matched	42
5.2.6	Clustering delle rappresentazioni profonde turn-level	43
5.2.7	Classificazione delle rappresentazioni profonde	45
5.3	Sintesi e discussione	46
5.4	Limiti dello studio	48
6	Conclusioni	49
	Bibliografia	51
	Ringraziamenti	56

Elenco delle figure

3.1	Schema semplificato dell'architettura Transformer encoder-decoder. L'encoder costruisce rappresentazioni contestuali dell'input, mentre il decoder le utilizza per generare la sequenza di output.	13
3.2	Schema semplificato di Whisper. L'audio viene trasformato in spettrogramma log-Mel, codificato dal Transformer e utilizzato dal decoder per generare i token testuali.	13
3.3	Schema semplificato di wav2vec 2.0. L'encoder convoluzionale estrae caratteristiche latenti dalla forma d'onda e il Transformer ne costruisce una rappresentazione contestuale.	14
4.1	Framework proposto per l'analisi clinica del parlato e del dolore.	21
5.1	Analisi di sensitività rispetto alla soglia minima di parlato del paziente. . . .	36
5.2	Curva ROC out-of-fold della regressione logistica basata sugli embedding Whisper-small aggregati a livello paziente per la classificazione DN4 binaria.	36
5.3	Proiezione UMAP degli embedding Whisper-small VALID-ONLY per la configurazione da 10 secondi, distinta in base alla classe DN4.	37
5.4	Proiezione PCA degli interventi vocali nello spazio delle caratteristiche acustiche e comportamentali-prosodiche.	39
5.5	Distribuzione delle ROC-AUC ottenute mediante Repeated Stratified 5-Fold Cross-Validation sul DN4 binario utilizzando le quote dei profili comportamentali.	40

Elenco delle tabelle

2.1	Confronto tra alcuni studi sull'analisi automatica del dolore mediante il segnale vocale. Le prestazioni non sono direttamente confrontabili a causa delle differenze nei dataset, nei target e nelle metriche utilizzate.	8
5.1	Analisi di sensitività per durata della finestra temporale e soglia minima di parlato del paziente.	35
5.2	Confronto delle soluzioni K-Means per la profilazione acustica.	37
5.3	Confronto delle soluzioni K-Means per la profilazione comportamentale e prosodica.	38
5.4	Associazione tra quote dei profili comportamentali e NRS/BPI	40
5.5	Prestazioni patient-level dei modelli Random Forest e XGBoost	42
5.6	Profili comportamentali/prosodici dei turni pain-related	43
5.7	Clustering K-Means a due gruppi prima e dopo il controllo della durata . . .	44
5.8	Prestazioni patient-level sul DN4 delle rappresentazioni profonde e della durata	45
5.9	Confronto delle principali strategie score-dependent sul DN4 binario.	47

Il dolore rappresenta un'esperienza complessa e multidimensionale, influenzata da componenti sensoriali, emotive, cognitive e sociali. La sua natura fortemente soggettiva rende particolarmente delicata la valutazione in ambito clinico, che si basa in larga misura su quanto riferito direttamente dal paziente attraverso scale e questionari standardizzati. Sebbene tali strumenti costituiscano un riferimento fondamentale nella pratica clinica, la misura ottenuta dipende inevitabilmente anche dalla percezione individuale e dalla capacità del soggetto di riconoscere, interpretare e comunicare la propria esperienza dolorosa. Queste caratteristiche motivano lo studio di fonti di informazione complementari, capaci di affiancare gli strumenti clinici tradizionali senza sostituirli. Il parlato rappresenta una fonte particolarmente interessante: la produzione vocale è infatti il risultato dell'interazione tra processi fisiologici, motori, cognitivi ed emotivi e può riflettere variazioni associate allo stato psicofisico dell'individuo. Inoltre, il segnale vocale può essere acquisito in maniera non invasiva durante una normale interazione clinica, rendendolo adatto a procedure di analisi automatica.

Lo sviluppo recente di tecniche di Intelligenza Artificiale e Machine Learning ha reso possibile analizzare il parlato non soltanto attraverso caratteristiche acustiche e prosodiche definite a priori, ma anche mediante rappresentazioni apprese automaticamente dal segnale audio e dal contenuto linguistico. Rimane tuttavia complesso stabilire in quale misura tali rappresentazioni riescano a catturare informazioni effettivamente riconducibili alla condizione clinica e quanto, invece, possano essere influenzate da caratteristiche proprie della conversazione o della registrazione. La natura multi-parlante delle interviste cliniche intro-

duce inoltre un'ulteriore difficoltà, poiché prima di qualsiasi analisi è necessario identificare correttamente le porzioni di parlato attribuibili al paziente.

A partire da tali considerazioni, il presente lavoro propone un framework computazionale per l'analisi automatica del parlato raccolto durante interviste cliniche multi-parlante. La procedura organizza i dati clinici e audio, distingue gli interlocutori e isola gli interventi vocali del paziente, dai quali vengono successivamente costruite rappresentazioni strutturate del parlato. Le rappresentazioni considerate comprendono informazioni acustiche e prosodiche interpretabili e rappresentazioni apprese automaticamente dal segnale audio e dal contenuto linguistico. Esse vengono analizzate mediante approcci non supervisionati e supervisionati, mantenendo il paziente come unità di valutazione e controllando possibili fattori legati alla struttura della conversazione. L'obiettivo non è proporre un biomarcatore vocale diagnostico né sostituire gli strumenti clinici esistenti, ma valutare quali informazioni possano essere ricavate dal parlato in un contesto clinico reale e in che misura possano contribuire, in maniera esplorativa, alla caratterizzazione del paziente.

La tesi è articolata in sei capitoli:

- **Capitolo 2:** presenta il contesto clinico e discute i principali contributi della letteratura relativi all'analisi del parlato e del dolore, evidenziandone potenzialità e limiti.
- **Capitolo 3:** introduce i concetti teorici e computazionali necessari alla comprensione delle tecniche utilizzate.
- **Capitolo 4:** descrive il dataset e la metodologia proposta, dalla preparazione delle registrazioni alla costruzione e all'analisi delle rappresentazioni del parlato.
- **Capitolo 5:** presenta e discute i risultati ottenuti e i limiti dello studio.
- **Capitolo 6:** riassume le principali evidenze emerse e le possibili direzioni di sviluppo futuro.

2.1 Valutazione clinica del dolore

Il dolore è un'esperienza personale e multidimensionale, influenzata da fattori biologici, psicologici e sociali e non riconducibile soltanto all'entità di un danno tissutale [1]. La sua valutazione si fonda quindi soprattutto sul *self-report*. Tra gli strumenti più utilizzati in letteratura rientrano la *Numeric Rating Scale* (NRS), il *Brief Pain Inventory* (BPI) e il *Douleur Neuropathique en 4 Questions* (DN4), rivolti ad aspetti differenti dell'esperienza dolorosa.

Numeric Rating Scale La *Numeric Rating Scale* (NRS) è uno degli strumenti più utilizzati per quantificare l'intensità del dolore percepito. Nella revisione sistematica di Hjermstad et al., che confronta NRS, *Visual Analogue Scale* e *Verbal Rating Scale*, la scala numerica mostra generalmente una migliore adesione da parte dei pazienti e risulta pratica nelle valutazioni ripetute [2]. Il suo principale vantaggio è la semplicità di somministrazione e interpretazione. Al tempo stesso, fornisce una misura unidimensionale, che non descrive la qualità del dolore né la sua interferenza sulla vita quotidiana. Anche il significato attribuito allo stesso punteggio e le soglie tra dolore lieve, moderato e severo possono variare in base alla popolazione e al contesto clinico [3].

Brief Pain Inventory Il *Brief Pain Inventory* (BPI) affianca alla severità del dolore una valutazione del suo impatto sul funzionamento quotidiano. Cleeland e Ryan ne documentano

l'impiego nel dolore oncologico e la successiva adozione in studi epidemiologici, clinici e di efficacia terapeutica, favorita dalla validazione in lingue e contesti culturali diversi [4]. Rispetto alla NRS, il BPI offre una descrizione più articolata, distinguendo pazienti con intensità simile ma conseguenze differenti su attività, umore, sonno e relazioni. Richiede però una somministrazione più estesa, dipende dal ricordo e dalla percezione del paziente e, se gli item vengono aggregati, può attenuare differenze rilevanti tra i singoli domini.

Douleur Neuropathique en 4 Questions Bouhassira et al. hanno sviluppato il *Douleur Neuropathique en 4 Questions* (DN4) confrontando pazienti con dolore associato a lesioni neurologiche e pazienti con dolore di origine somatica [5]. Lo strumento consente uno screening breve e standardizzato della possibile componente neuropatica e considera quindi la natura del dolore, anziché soltanto la sua intensità. Il risultato non costituisce però una diagnosi autonoma: le prestazioni possono variare in base alla popolazione esaminata e, nella versione completa, dipendono anche dalla corretta esecuzione della valutazione clinica.

Complementarità e limiti Gli studi mostrano che NRS, BPI e DN4 non sono intercambiabili: la prima sintetizza l'intensità percepita, il secondo considera anche l'interferenza sulla vita quotidiana, mentre il terzo supporta lo screening della componente neuropatica. Il loro uso congiunto permette una valutazione più completa, ma non elimina la dipendenza dal *self-report* e dal contesto. Ciò ha favorito lo studio di fonti complementari, tra cui il parlato, acquisibile in modo non invasivo e potenzialmente sensibile a variazioni fisiologiche, motorie, cognitive ed emotive.

2.2 Il parlato come fonte di biomarcatori digitali

La letteratura sulla *Digital Health* ha studiato il parlato come fonte di biomarcatori digitali in diversi ambiti clinici. Descrittori acustici e prosodici, come frequenza fondamentale, intensità, jitter, shimmer, rapporto armonico-rumore, ritmo e pause, sono interpretabili e riconducibili a specifici aspetti della produzione vocale. Possono però essere influenzati anche da età, sesso, stato emotivo, fatica, apparato fonatorio, compito linguistico e condizioni di registrazione; una loro variazione non è quindi attribuibile in modo univoco a uno stato clinico [6]. Le rappresentazioni profonde apprese dal segnale audio possono modellare configurazioni più complesse e ridurre la selezione manuale delle caratteristiche, ma sono meno interpretabili e dipendono dalla quantità e dalla rappresentatività dei dati.

Vocalizzazioni non verbali e dolore Una prima linea di ricerca ha analizzato gemiti, lamenti e altre vocalizzazioni non verbali. La revisione sistematica di Helmer et al. considera 35 studi e rileva un'associazione tra vocalizzazione e dolore nella maggior parte dei lavori esaminati [7]. L'approccio può essere utile quando il *self-report* è difficile da ottenere, poiché valorizza un comportamento osservabile. Il tipo di vocalizzazione varia però con l'età, le caratteristiche individuali e la condizione dolorosa. Il segnale vocale descrive pertanto soltanto una parte del fenomeno e risulta più affidabile se associato ad altri indicatori clinici e comportamentali.

Caratteristiche acustiche delle vocalizzazioni Lautenbacher et al. hanno confrontato vocalizzazioni prodotte in condizioni basali e durante stimolazioni termiche dolorose e non dolorose, analizzando frequenza fondamentale, variazioni fonatorie e intensità [8]. Pitch e intensità sono aumentati soprattutto nelle vocali più simili a gemiti, senza un andamento uniforme in tutte le produzioni. Lo studio mostra il vantaggio dei descrittori interpretabili, ma anche la loro dipendenza dal tipo di vocalizzazione e dal compito. I risultati ottenuti su vocali isolate e dolore indotto non sono quindi direttamente trasferibili al parlato spontaneo o al dolore persistente.

Parlato naturale e dolore acuto Gonzales et al. hanno confrontato vocali e monologhi prodotti da soggetti sani in presenza e in assenza di stimolazione termica dolorosa [9]. Durante il monologo il dolore è risultato associato a un aumento del ritmo sillabico e del rapporto tra parlato e pause; nella produzione vocalica è stata invece osservata una riduzione del livello medio di pressione sonora. Sono emerse anche associazioni esplorative con la sensibilità individuale al dolore. Il parlato continuo rende l'analisi più vicina a una normale interazione verbale, ma lo studio resta limitato da un campione contenuto, da una condizione acuta indotta e dalla dipendenza dei risultati dal compito svolto.

Parlato clinico e classificazione automatica Oshrat et al. hanno analizzato circa 400 campioni vocali raccolti da 27 pazienti adulti in un contesto ospedaliero naturale, distinguendo tra dolore non significativo e significativo mediante caratteristiche prosodiche e modelli di classificazione [10]. Le caratteristiche progettate specificamente per lo studio hanno migliorato la discriminazione rispetto all'impiego dei soli descrittori vocali convenzionali. Il principale vantaggio consiste nell'utilizzo di registrazioni provenienti da pazienti reali e non da soggetti sani sottoposti a dolore sperimentale. La numerosità contenuta del campione,

la formulazione binaria del problema e la dipendenza delle caratteristiche dal contesto di acquisizione limitano però la generalizzabilità dei risultati.

Un ulteriore esperimento in condizioni cliniche reali è stato condotto da Tsai et al. utilizzando registrazioni vocali acquisite durante il triage in pronto soccorso [11]. Gli autori hanno combinato rappresentazioni acustiche *stacked bottleneck* e reti LSTM, ottenendo un'accuratezza del 72.3% nella distinzione binaria tra dolore lieve e severo e del 54.2% nella classificazione a tre livelli. Lo studio mostra che la componente prosodica può contenere informazione utile anche durante una normale interazione clinica. Le prestazioni diminuiscono tuttavia nel passaggio dal problema binario a quello multiclass, evidenziando la difficoltà di distinguere livelli intermedi di un fenomeno soggettivo. I risultati rimangono inoltre legati allo specifico contesto di triage e alle etichette derivate dalle valutazioni cliniche e dal *self-report*.

Corpus sperimentali e rappresentazioni profonde Ren et al. hanno introdotto il *Düsseldorf Acute Pain Corpus*, comprendente 844 registrazioni di 80 soggetti sottoposti a una *Cold Pressor Task* [12]. Il corpus comprende parlato letto e dialogo spontaneo in lingua tedesca ed è suddiviso in insiemi di training, validation e test indipendenti rispetto al parlante. Gli autori hanno confrontato caratteristiche ComParE, MFCC e rappresentazioni Deep Spectrum mediante SVM e reti LSTM, ottenendo come risultato migliore una *Unweighted Average Recall* del 42.7% nella classificazione a tre livelli. La separazione patient-independent costituisce un punto di forza metodologico, perché impedisce al modello di riconoscere indirettamente l'identità dei soggetti. Le prestazioni contenute e la difficoltà nel riconoscere la classe severa mostrano l'effetto della numerosità limitata e dello sbilanciamento tra i livelli di dolore.

Williams et al. hanno successivamente raccolto 1,947 utterance da 15 partecipanti durante una *Cold Pressor Task*, utilizzando caratteristiche acustiche interpretabili e confrontando SVM, regressione logistica e reti multilivello [13]. Sul test set misto, il modello SVM raggiunge un F1-score normalizzato del 73.8% nel compito binario e del 67.3% nella classificazione a tre livelli. L'analisi mediante SHAP permette inoltre di individuare il contributo di descrittori spettrali, energetici e di qualità vocale, migliorando l'interpretabilità delle decisioni. Gli autori osservano tuttavia una scarsa generalizzazione sui parlanti non presenti durante l'addestramento. Il campione comprende soltanto 15 soggetti ed è fortemente sbilanciato rispetto al genere, mostrando come un numero elevato di utterance non equivalga necessariamente a un numero adeguato di osservazioni indipendenti. Dao et al. hanno infine pubblicato il dataset TAME Pain, composto da 7,039 utterance raccolte da 51 partecipanti durante una *Cold Pressor Task* e associate ai livelli di dolore riferiti [14]. La disponibilità pubblica del corpus

favorisce la riproducibilità degli esperimenti e il confronto tra descrittori acustici e modelli di apprendimento automatico. Anche in questo caso, tuttavia, i dati provengono da soggetti prevalentemente sani, da dolore acuto indotto e da compiti vocali definiti dal protocollo. Rimane pertanto incerto quanto le relazioni osservate possano trasferirsi al dolore persistente e al parlato spontaneo prodotto durante interviste cliniche.

Confronto tra gli approcci e generalizzabilità Il confronto tra gli studi mostra risultati promettenti, ma anche un'elevata eterogeneità sperimentale. Cambiano il tipo di dolore considerato, la modalità di induzione, il compito vocale, la numerosità dei soggetti, la definizione delle classi e le metriche di valutazione. Accuratezza, F1-score e *Unweighted Average Recall* non sono pertanto direttamente confrontabili tra lavori differenti. La revisione di Borna et al. evidenzia inoltre che i principali ostacoli all'impiego clinico dei sistemi vocali sono costituiti dalla ridotta dimensione dei dataset, dalla variabilità delle popolazioni, dal rischio di bias e dalla limitata generalizzabilità dei modelli [15].

Un ulteriore elemento critico riguarda l'unità statistica utilizzata nella valutazione. I dataset possono contenere centinaia o migliaia di campioni vocali, ma tali osservazioni provengono generalmente da un numero molto più ridotto di soggetti. Quando gli interventi dello stesso partecipante vengono distribuiti tra training e test, il modello può sfruttare caratteristiche individuali della voce anziché informazioni effettivamente associate al dolore. La separazione patient-level costituisce quindi un requisito essenziale per stimare la capacità di generalizzare a nuovi pazienti. Nel complesso, la letteratura non identifica ancora una caratteristica vocale o una rappresentazione profonda capace di fornire prestazioni robuste in popolazioni e condizioni di acquisizione differenti.

2.3 Contributo della tesi

Limiti emersi dalla letteratura Il confronto sintetizzato nella Tabella 2.1 mostra che il segnale vocale può contenere informazioni associate al dolore, ma non è stato ancora individuato un biomarcatore vocale unico e generalizzabile. Le caratteristiche acustiche e prosodiche tradizionali sono interpretabili, ma dipendono dal parlante, dal compito linguistico, dalle condizioni di registrazione e dalle modalità con cui il dolore viene espresso. Le rappresentazioni profonde possono modellare configurazioni più complesse, ma richiedono dataset sufficientemente ampi e risultano meno trasparenti dal punto di vista clinico.

Studio	Contesto e campione	Approccio e risultato	Vantaggi e limiti
Oshrat et al. [10]	400 campioni di 27 pazienti in ambiente ospedaliero	Caratteristiche prosodiche e classificazione binaria del dolore	Contesto clinico reale; campione ridotto e valutazione limitata a due classi.
Tsai et al. [11]	Registrazioni vocali durante il triage in pronto soccorso	Stacked bottleneck e LSTM; accuracy 72.3% binaria e 54.2% multiclass	Elevata validità ecologica; prestazioni inferiori nella distinzione dei livelli intermedi.
Ren et al. [12]	844 registrazioni di 80 soggetti durante dolore acuto indotto	ComParE, MFCC e Deep Spectrum; migliore UAR pari al 42.7%	Valutazione speaker-independent; dolore indotto, classi sbilanciate e prestazioni contenute.
Williams et al. [13]	1 947 utterance di 15 partecipanti durante dolore acuto indotto	Feature acustiche e SVM; F1-score 73.8% binario e 67.3% multiclass sul test misto	Approccio interpretabile; pochi partecipanti, sbilanciamento di genere e debole generalizzazione a nuovi parlanti.
Dao et al. [14]	7 039 utterance di 51 partecipanti durante una Cold Pressor Task	Corpus pubblico con segnale audio e livelli di dolore riferiti	Favorisce riproducibilità e confronto; soggetti sani, dolore acuto e compiti controllati.

Tabella 2.1: Confronto tra alcuni studi sull'analisi automatica del dolore mediante il segnale vocale. Le prestazioni non sono direttamente confrontabili a causa delle differenze nei dataset, nei target e nelle metriche utilizzate.

Gran parte degli studi utilizza inoltre soggetti sani sottoposti a dolore acuto indotto, vocalizzazioni isolate o compiti vocali controllati [8, 12–14]. Tali condizioni migliorano il controllo sperimentale, ma non riproducono completamente il dolore persistente e la variabilità delle conversazioni cliniche reali. I lavori condotti in ambiente ospedaliero presentano una maggiore validità ecologica, ma coinvolgono generalmente campioni contenuti e contesti applicativi specifici [10, 11].

Un ulteriore limite riguarda la relazione tra numero di registrazioni e numero di soggetti. Migliaia di segmenti vocali possono provenire da poche decine di partecipanti e non costituiscono osservazioni statisticamente indipendenti. La debole generalizzazione ai parlanti non osservati, riscontrata anche da Williams et al. [13], evidenzia la necessità di mantenere tutti i campioni dello stesso paziente nel medesimo insieme di training o test. Rimangono infine poco esplorati il confronto diretto tra caratteristiche interpretabili e rappresentazioni profonde, l'integrazione tra informazione acustica e linguistica e il controllo dei possibili confondenti conversazionali, tra cui la durata degli interventi vocali.

Contributi del lavoro La tesi affronta i limiti evidenziati attraverso un framework applicato a interviste cliniche multi-parlante, caratterizzate da conversazioni spontanee e da condizioni di acquisizione meno controllate rispetto agli esperimenti di laboratorio. La diarizzazione e l'assegnazione dei ruoli consentono di isolare gli interventi vocali del paziente, riducendo il rischio che il parlato del personale sanitario contribuisca alle rappresentazioni analizzate.

Il segnale viene osservato mediante unità e rappresentazioni complementari. Le finestre temporali di durata controllata permettono di confrontare segmenti omogenei, mentre gli interventi vocali reali preservano maggiormente la struttura spontanea della conversazione. Su queste unità vengono analizzate sia caratteristiche acustiche, prosodiche e comportamentali direttamente interpretabili, sia embedding profondi audio, testuali e multimodali ottenuti mediante Whisper-small, Wav2Vec2 e MiniLM. Il confronto permette di verificare se eventuali associazioni siano specifiche di una rappresentazione oppure ricorrano in spazi informativi differenti.

La scoperta della struttura latente viene mantenuta separata dalla valutazione clinica: i cluster sono costruiti senza utilizzare NRS, BPI o DN4 e gli score vengono introdotti soltanto nelle analisi successive. Negli esperimenti supervisionati la separazione tra training e test è effettuata a livello paziente, evitando che interventi vocali dello stesso soggetto compaiano in entrambi gli insiemi. La durata viene inoltre analizzata esplicitamente come possibile fattore confondente e confrontata con le rappresentazioni ad alta dimensionalità.

Infine, l'individuazione degli interventi *pain-related* consente di restringere l'analisi alle porzioni della conversazione nelle quali il paziente fa riferimento al dolore e di effettuare confronti all'interno dello stesso soggetto. Il contributo non consiste quindi nella proposta di uno strumento diagnostico autonomo, ma in una metodologia riproducibile per studiare il parlato clinico reale integrando rappresentazioni interpretabili e profonde, analisi non supervisionate, modelli patient-level e controlli dei principali fattori conversazionali.

In questo capitolo saranno presentati e spiegati i concetti fondamentali necessari per comprendere appieno i contenuti trattati nei capitoli successivi.

3.1 Caratteristiche acustiche, prosodiche e temporali

Il parlato può essere descritto mediante parametri che rappresentano la produzione vocale e la sua organizzazione nel tempo.

Frequenza fondamentale e intensità La frequenza fondamentale, indicata con F_0 e misurata in hertz, corrisponde alla frequenza di vibrazione delle corde vocali nei tratti sonori. Essa è il principale correlato acustico del *pitch*, cioè della percezione di una voce più grave o più acuta. L'intensità descrive invece l'energia del segnale ed è generalmente espressa in decibel; dal punto di vista percettivo è collegata alla sensazione di maggiore o minore volume della voce.

Jitter, shimmer e rapporto armonico-rumore Il jitter misura le variazioni tra cicli consecutivi della durata del periodo fondamentale e descrive l'irregolarità della fonazione. Lo shimmer quantifica le variazioni dell'ampiezza e quindi l'instabilità dell'intensità. Il rapporto armonico-rumore, o HNR, confronta l'energia delle componenti periodiche con quella delle componenti rumorose: valori elevati indicano una voce più armonica, mentre valori inferiori segnalano una maggiore presenza di rumore.

Ritmo e pause Il ritmo del parlato viene rappresentato attraverso grandezze quali velocità di eloquio, durata dei turni e distribuzione delle pause. La velocità di eloquio indica quante unità linguistiche, ad esempio sillabe o parole, vengono prodotte nell'unità di tempo. La durata e la frequenza delle pause descrivono le interruzioni del flusso verbale, mentre il rapporto tra tempo di parlato e silenzio quantifica la porzione del turno effettivamente occupata dalla voce.

Interpretazione Nessuna caratteristica è specifica di una sola condizione clinica. Età, sesso, lingua, stato emotivo, affaticamento, apparato fonatorio, durata del turno e condizioni di registrazione possono modificare il segnale. Le misure devono quindi essere interpretate congiuntamente, controllando i possibili fattori confondenti.

3.2 Representation learning e Transformer

Gli approcci tradizionali all'analisi del parlato utilizzano caratteristiche definite a priori e direttamente interpretabili. Il *representation learning* permette invece a un modello di apprendere dai dati rappresentazioni numeriche, denominate *embedding*, che sintetizzano proprietà complesse del segnale. Gli *embedding* possono essere utilizzati per visualizzazione, clustering e classificazione. I modelli pre-addestrati consentono inoltre di estrarre tali rappresentazioni senza addestrare una rete profonda da zero sul dataset disponibile.

Alla base di molti modelli contemporanei si trova l'architettura Transformer, introdotta da Vaswani et al. [16]. Il suo elemento principale è il meccanismo di *self-attention*, che consente di mettere in relazione tutte le posizioni di una stessa sequenza e di costruire rappresentazioni dipendenti dal contesto.

Self-attention Sia $\mathbf{X} \in \mathbb{R}^{n \times d}$ una sequenza composta da n vettori di dimensione d . A partire da essa vengono costruite, mediante trasformazioni lineari apprese, tre matrici:

$$\mathbf{Q} = \mathbf{X}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{X}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{X}\mathbf{W}_V, \quad (3.2.1)$$

dove $\mathbf{Q}$, $\mathbf{K}$ e $\mathbf{V}$ rappresentano rispettivamente le matrici delle *query*, delle *key* e dei *value*, mentre $\mathbf{W}_Q$, $\mathbf{W}_K$ e $\mathbf{W}_V$ sono matrici di parametri apprese durante l'addestramento. Il meccanismo di attenzione è definito come:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right) \mathbf{V}, \quad (3.2.2)$$

dove d_k è la dimensionalità delle query e delle key. Il prodotto $\mathbf{QK}^T$ misura la compatibilità tra ogni coppia di posizioni della sequenza, mentre il fattore $\sqrt{d_k}$ evita che prodotti scalari molto elevati rendano la funzione softmax eccessivamente concentrata.

Indicando con $\mathbf{q}_i$, $\mathbf{k}_j$ e $\mathbf{v}_j$ i vettori associati rispettivamente alle posizioni i e j , il peso assegnato dalla posizione i alla posizione j è:

$$\alpha_{ij} = \frac{\exp(\mathbf{q}_i^T \mathbf{k}_j / \sqrt{d_k})}{\sum_{\ell=1}^n \exp(\mathbf{q}_i^T \mathbf{k}_\ell / \sqrt{d_k})}. \quad (3.2.3)$$

I coefficienti α_{ij} appartengono all'intervallo $[0, 1]$ e, per ogni posizione i , soddisfano $\sum_{j=1}^n \alpha_{ij} = 1$. L'output relativo alla posizione i è quindi una somma pesata dei value:

$$\mathbf{h}_i = \sum_{j=1}^n \alpha_{ij} \mathbf{v}_j. \quad (3.2.4)$$

Un peso elevato indica che la posizione j è particolarmente rilevante per interpretare la posizione i . Il termine *self-attention* deriva dal fatto che query, key e value sono ottenuti dalla stessa sequenza di input. Nei modelli per il parlato questo meccanismo permette a ciascun istante di integrare informazioni provenienti da altre porzioni della sequenza, anche temporalmente distanti. Nei Transformer multi-head il calcolo viene ripetuto in parallelo da più teste, consentendo al modello di apprendere differenti tipi di relazione.

La Figura 3.1 mostra il ruolo della self-attention all'interno dell'architettura Transformer.

3.3 Modelli pre-addestrati per il parlato

Whisper e wav2vec 2.0 sono modelli Transformer pre-addestrati con obiettivi differenti e possono essere impiegati come estrattori di rappresentazioni del segnale audio.

Whisper Whisper è un modello encoder-decoder sviluppato per il riconoscimento automatico e la traduzione del parlato [17]. L'audio viene convertito in uno spettrogramma log-Mel; l'encoder lo trasforma in una sequenza di rappresentazioni latenti e il decoder utilizza tali informazioni per generare il testo. Whisper-small produce vettori di dimensionalità 768 per ciascuna posizione temporale. Per ottenere un solo vettore di dimensione fissa è quindi necessario aggregare la sequenza mediante una procedura di pooling. Quando viene utilizzato come estrattore di caratteristiche, l'embedding non assume un significato clinico diretto, ma costituisce una rappresentazione da verificare empiricamente. Il flusso di elaborazione di Whisper è schematizzato nella Figura 3.2.




Figura 3.1: Schema semplificato dell'architettura Transformer encoder-decoder. L'encoder costruisce rappresentazioni contestuali dell'input, mentre il decoder le utilizza per generare la sequenza di output.




Figura 3.2: Schema semplificato di Whisper. L'audio viene trasformato in spettrogramma log-Mel, codificato dal Transformer e utilizzato dal decoder per generare i token testuali.

Wav2Vec2 Wav2vec 2.0 è un modello *self-supervised* per il *representation learning* del parlato [18]. Un encoder convoluzionale trasforma la forma d'onda in caratteristiche latenti, mentre una rete Transformer costruisce rappresentazioni contestuali. Durante il pre-addestramento alcune porzioni della sequenza vengono mascherate e il modello impara a riconoscere la rappresentazione corretta tra alternative negative. Il modello `facebook/wav2vec2-base` produce embedding di dimensionalità 768. Anche in questo caso le rappresentazioni temporali devono essere aggregate per ottenere un vettore associato a ciascun turno.

L'architettura di wav2vec 2.0 è rappresentata nella Figura 3.3.

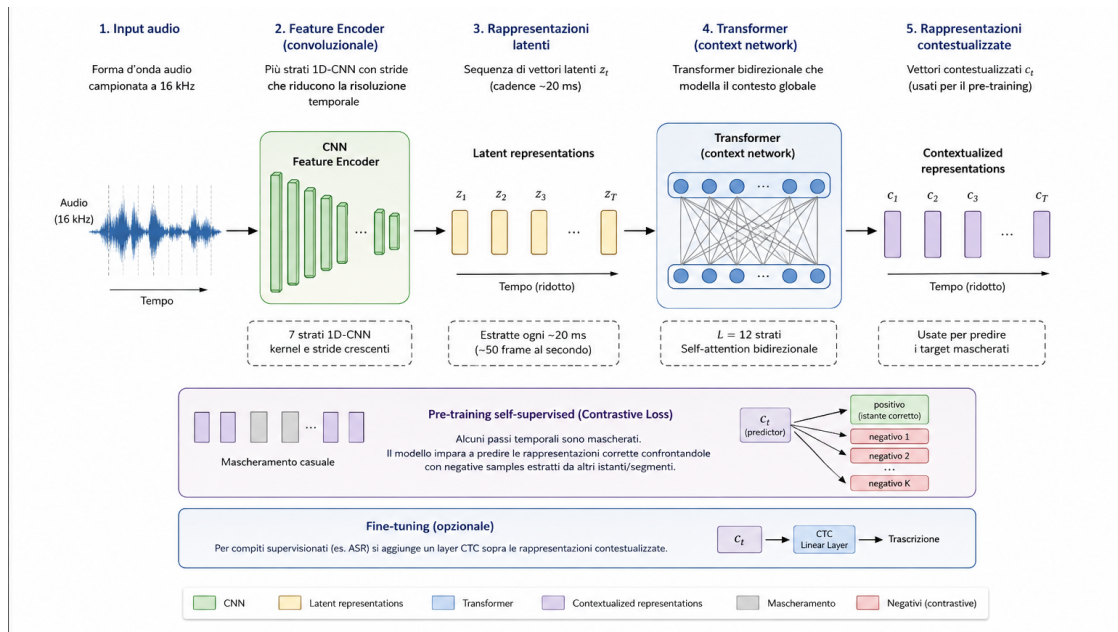


Figura 3.3: Schema semplificato di wav2vec 2.0. L'encoder convoluzionale estrae caratteristiche latenti dalla forma d'onda e il Transformer ne costruisce una rappresentazione contestuale.

I due modelli differiscono per obiettivo di pre-addestramento. Whisper è ottimizzato per riconoscimento e traduzione, mentre wav2vec 2.0 apprende dal segnale audio mediante un obiettivo auto-supervisionato. Il confronto permette di verificare se producano rappresentazioni con proprietà diverse.

3.4 Rappresentazioni testuali e multimodali

Le trascrizioni automatiche consentono di affiancare al segnale audio una rappresentazione del contenuto linguistico. I modelli Sentence-BERT trasformano frasi o brevi testi in vettori di dimensione fissa adatti ad analisi di similarità, clustering e classificazione [19].

Viene impiegato il modello `paraphrase-multilingual-MiniLM-L12-v2` della famiglia MiniLM [20]. Esso associa a ogni trascrizione un embedding di 384 dimensioni.

Early fusion Una strategia di integrazione multimodale è l'*early fusion*, nella quale le rappresentazioni delle diverse modalità vengono unite prima dell'analisi [21]. Siano $\mathbf{a} \in \mathbb{R}^{d_a}$ l'embedding audio e $\mathbf{t} \in \mathbb{R}^{d_t}$ l'embedding testuale. Dopo la normalizzazione separata,

$$\hat{\mathbf{a}} = \frac{\mathbf{a}}{\|\mathbf{a}\|_2}, \quad \hat{\mathbf{t}} = \frac{\mathbf{t}}{\|\mathbf{t}\|_2}, \quad (3.4.1)$$

la rappresentazione multimodale è ottenuta mediante concatenazione:

$$\mathbf{z}_{\text{fusion}} = \left[\frac{1}{\sqrt{2}}\hat{\mathbf{a}}; \frac{1}{\sqrt{2}}\hat{\mathbf{t}} \right] \in \mathbb{R}^{d_a+d_t}. \quad (3.4.2)$$

I simboli d_a e d_t indicano rispettivamente il numero di componenti audio e testuali; $\|\cdot\|_2$ è la norma euclidea; il punto e virgola indica che i due vettori vengono accodati. La normalizzazione assegna a ciascuna modalità norma unitaria, evitando che una prevalga soltanto per la diversa scala numerica. Ad esempio, se $\mathbf{a} = (3, 4)$ e $\mathbf{t} = (0, 2)$, dopo la normalizzazione si ottengono $\hat{\mathbf{a}} = (0.6, 0.8)$ e $\hat{\mathbf{t}} = (0, 1)$. L'*early fusion* restituisce quindi:

$$\mathbf{z}_{\text{fusion}} = \left(\frac{0.6}{\sqrt{2}}, \frac{0.8}{\sqrt{2}}, 0, \frac{1}{\sqrt{2}} \right) \approx (0.4243, 0.5657, 0, 0.7071).$$

Il contributo delle due modalità possiede così la stessa norma prima delle successive analisi.

3.5 Riduzione dimensionale e clustering

Le rappresentazioni possono avere dimensionalità elevata. La Principal Component Analysis (PCA) proietta i dati su componenti ortogonali ordinate in base alla varianza spiegata [22]. Può essere impiegata per l'esplorazione dei dati o come riduzione dimensionale preliminare. UMAP è invece una tecnica non lineare utilizzata soprattutto per visualizzare la struttura locale di dati ad alta dimensionalità [23]; una separazione nella proiezione bidimensionale non dimostra, da sola, l'esistenza di gruppi clinicamente significativi.

Gli algoritmi di clustering raggruppano osservazioni simili senza label. K-Means assegna i campioni a K centroidi minimizzando la variabilità interna [24]; i Gaussian Mixture Model descrivono i gruppi in modo probabilistico; il metodo gerarchico di Ward unisce progressivamente i gruppi minimizzando l'incremento della varianza interna [25]; HDBSCAN individua regioni dense e può classificare alcune osservazioni come rumore [26].

Silhouette score Per un'osservazione i , il Silhouette score è definito come [27]

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}, \quad (3.5.1)$$

dove $a(i)$ è la distanza media tra i e le altre osservazioni del proprio cluster, mentre $b(i)$ è la più piccola distanza media tra i e le osservazioni di un altro cluster. In particolare, indicando con C_i il cluster di i , con $|C|$ il numero di elementi del cluster C e con $d(i, j)$ la distanza tra le osservazioni i e j ,

$$a(i) = \frac{1}{|C_i| - 1} \sum_{\substack{j \in C_i \\ j \neq i}} d(i, j), \quad b(i) = \min_{C \neq C_i} \frac{1}{|C|} \sum_{j \in C} d(i, j). \quad (3.5.2)$$

Il valore $s(i)$ appartiene all'intervallo $[-1, 1]$: valori vicini a 1 indicano un'osservazione compatta nel proprio cluster e lontana dagli altri; valori prossimi a 0 indicano sovrapposizione tra gruppi; valori negativi suggeriscono una possibile assegnazione a un cluster non appropriato. Per un cluster formato da una sola osservazione si pone convenzionalmente $s(i) = 0$. Il punteggio complessivo è la media $S = \frac{1}{n} \sum_{i=1}^n s(i)$, dove n è il numero totale di osservazioni.

Adjusted Rand Index L'Adjusted Rand Index (ARI) confronta due partizioni correggendo l'accordo atteso per caso [28]. Siano $U = \{U_1, \dots, U_r\}$ e $V = \{V_1, \dots, V_c\}$ le partizioni delle stesse n osservazioni e sia $n_{ij} = |U_i \cap V_j|$ il numero di elementi condivisi dai cluster U_i e V_j . Ponendo $a_i = \sum_j n_{ij}$ e $b_j = \sum_i n_{ij}$, l'indice è

$$\text{ARI} = \frac{\sum_{i,j} \binom{n_{ij}}{2} - \frac{(\sum_i \binom{a_i}{2}) (\sum_j \binom{b_j}{2})}{\binom{n}{2}}}{\frac{1}{2} \left[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2} \right] - \frac{(\sum_i \binom{a_i}{2}) (\sum_j \binom{b_j}{2})}{\binom{n}{2}}}. \quad (3.5.3)$$

Il coefficiente $\binom{x}{2} = x(x-1)/2$ conta le coppie ottenibili da x elementi; a_i e b_j sono le numerosità dei cluster delle due partizioni. L'ARI vale 1 quando le partizioni coincidono, è circa 0 quando l'accordo è quello atteso casualmente e può assumere valori negativi quando l'accordo è peggiore di quello casuale; il limite inferiore dipende dalle numerosità dei cluster. Nell'analisi di stabilità, un valore elevato indica che il clustering cambia poco tra inizializzazioni o ricampionamenti.

Altri indici interni L'indice di Calinski–Harabasz confronta la dispersione tra cluster con quella interna: valori maggiori indicano gruppi più compatti e separati. L'indice di Davies–Bouldin misura invece la similarità media tra ciascun cluster e quello più simile: valori inferiori indicano una partizione migliore. Queste misure descrivono la geometria dei gruppi, non la loro rilevanza clinica.

Controllo dei fattori confondenti Una struttura latente può riflettere proprietà estranee al fenomeno di interesse. La durata del turno, ad esempio, modifica la quantità di informazione disponibile e può influenzare la geometria degli embedding. Per valutarne l'effetto è possibile residualizzare ogni componente rispetto a $\log(1 + d)$ e al relativo termine quadratico, dove d è la durata del turno, e ripetere il clustering sui residui. I cluster vengono costruiti senza label; gli score NRS, BPI e DN4 vengono introdotti soltanto dopo, per verificare eventuali associazioni. Un cluster stabile viene quindi interpretato come profilo descrittivo del parlato e non come categoria clinica.

3.6 Classificazione supervisionata

La classificazione supervisionata verifica se caratteristiche o embedding contengano informazione discriminativa rispetto a un target noto. Random Forest combina più alberi decisionali costruiti introducendo casualità nei campioni e nelle caratteristiche, riducendo la varianza rispetto a un singolo albero [29]. XGBoost costruisce invece gli alberi in sequenza, facendo correggere a ciascuno gli errori dell'insieme precedente; regolarizzazione e sottocampionamento ne controllano la complessità [30].

Balanced accuracy Per un problema con K classi, la balanced accuracy è la media del richiamo calcolato su ciascuna classe:

$$BA = \frac{1}{K} \sum_{k=1}^K \frac{TP_k}{TP_k + FN_k}. \quad (3.6.1)$$

TP_k è il numero di osservazioni della classe k classificate correttamente, mentre FN_k è il numero di osservazioni della stessa classe assegnate erroneamente a un'altra classe. Ogni classe contribuisce con lo stesso peso, anche quando il dataset è sbilanciato. La metrica varia tra 0 e 1: 1 indica classificazione perfetta; il valore atteso di una predizione casuale è $1/K$, pari a 0,5 nel caso binario.

F1-score Il richiamo e la precisione della classe positiva sono

$$R = \frac{TP}{TP + FN}, \quad P = \frac{TP}{TP + FP}, \quad (3.6.2)$$

dove TP indica i veri positivi, FN i positivi classificati come negativi e FP i negativi classificati come positivi. L’F1-score è la media armonica di precisione e richiamo:

$$F_1 = 2 \frac{P R}{P + R} = \frac{2TP}{2TP + FP + FN}. \quad (3.6.3)$$

La metrica appartiene a $[0, 1]$: vale 1 quando non sono presenti falsi positivi o falsi negativi e diminuisce quando una delle due quantità aumenta. Poiché non considera i veri negativi, deve essere interpretata insieme ad altre metriche. Nei problemi multiclasse può essere calcolata per ciascuna classe e poi mediata.

ROC-AUC La curva ROC dipende dalla soglia decisionale. Essa rappresenta il tasso di veri positivi $TPR = TP / (TP + FN)$ rispetto al tasso di falsi positivi $FPR = FP / (FP + TN)$; TN indica i veri negativi. L’area sotto la curva può essere interpretata come

$$\text{ROC-AUC} = \Pr(s(\mathbf{x}^+) > s(\mathbf{x}^-)) + \frac{1}{2} \Pr(s(\mathbf{x}^+) = s(\mathbf{x}^-)), \quad (3.6.4)$$

dove $s(\mathbf{x}^+)$ è il punteggio assegnato dal modello a un esempio positivo e $s(\mathbf{x}^-)$ quello assegnato a un esempio negativo. La ROC-AUC varia tra 0 e 1: 1 indica una separazione perfetta, 0,5 una capacità discriminativa equivalente al caso e valori inferiori a 0,5 un ordinamento prevalentemente invertito.

Validazione Quando le osservazioni sono turni ma le label sono associate ai pazienti, tutti i turni dello stesso soggetto devono rimanere nello stesso fold. Imputazione, scaling, PCA e selezione delle caratteristiche vengono adattati soltanto sui dati di training per evitare *data leakage*. Un *permutation test* può infine confrontare la metrica osservata con una distribuzione nulla ottenuta permutando le label e ripetendo la valutazione.

3.7 Multiple Instance Learning

Il Multiple Instance Learning (MIL) è adatto ai problemi nei quali una label è disponibile per un insieme di osservazioni, detto *bag*, ma non per le singole instance. Nel presente contesto il paziente i costituisce una bag $B_i = \{\mathbf{x}_{i1}, \dots, \mathbf{x}_{im_i}\}$ formata da m_i turni, mentre la label clinica y_i è associata all’intero soggetto.

Nell'Attention-based MIL ogni turno viene trasformato in un vettore $\mathbf{h}_{ij}$ e riceve un peso di attenzione:

$$e_{ij} = \mathbf{w}^T \tanh(\mathbf{V}\mathbf{h}_{ij}), \quad \alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{\ell=1}^{m_i} \exp(e_{i\ell})}, \quad \mathbf{z}_i = \sum_{j=1}^{m_i} \alpha_{ij} \mathbf{h}_{ij}. \quad (3.7.1)$$

$\mathbf{h}_{ij}$ è la rappresentazione del turno j del paziente i ; $\mathbf{V}$ e $\mathbf{w}$ sono parametri appresi; e_{ij} è il punteggio di attenzione non normalizzato; α_{ij} è il peso assegnato al turno. I pesi appartengono a $[0, 1]$ e soddisfano $\sum_j \alpha_{ij} = 1$. Il vettore $\mathbf{z}_i$ è quindi la rappresentazione patient-level utilizzata dal classificatore per stimare la label y_i [31].

Ad esempio, per tre turni con rappresentazioni $\mathbf{h}_{i1} = (1, 0)$, $\mathbf{h}_{i2} = (0, 1)$ e $\mathbf{h}_{i3} = (1, 1)$ e pesi $\alpha_i = (0,6, 0,3, 0,1)$, si ottiene

$$\mathbf{z}_i = 0,6(1, 0) + 0,3(0, 1) + 0,1(1, 1) = (0,7, 0,4). \quad (3.7.2)$$

Il primo turno contribuisce maggiormente alla rappresentazione del paziente, ma non riceve una label individuale. Il MIL evita così di assumere che tutti i turni esprimano allo stesso modo l'informazione associata allo score clinico e mantiene la valutazione a livello di soggetto.

Il presente capitolo descrive il framework sviluppato per trasformare le interviste cliniche multi-parlante in rappresentazioni strutturate del parlato del paziente. Vengono presentate le principali fasi di elaborazione e le strategie di analisi adottate sui dati ottenuti.¹

Panoramica del framework Presentato in Figura ??, la fase comune comprende: organizzazione di audio e metadati, speaker diarization, selezione del canale canonico, assegnazione dei ruoli conversazionali e isolamento degli intervalli vocali del paziente.

A partire dagli intervalli del paziente vengono costruiti due flussi principali. Il **ramo Whisper a finestre fisse** utilizza segmenti non sovrapposti per estrarre embedding successivamente aggregati a livello paziente. Il **ramo degli interventi vocali** ricostruisce invece gli interventi vocali reali del paziente (*speaker turn*), ossia porzioni continue di parlato delimitate da una pausa o dall'intervento di un altro interlocutore. Da ciascun intervento vengono estratte caratteristiche interpretabili e, nelle analisi aggiuntive, embedding Whisper-small, Wav2Vec2 e MiniLM, oltre a una rappresentazione multimodale audio-testo. Le rappresentazioni vengono studiate mediante clustering e modelli supervisionati, mantenendo il paziente come unità di valutazione. Le trascrizioni automatiche vengono inoltre utilizzate per individuare i turni pain-related e confrontarli con il resto della conversazione controllando la durata. La scelta di articolare il framework in più rami risponde alla necessità di osservare il parlato a livelli differenti. Le finestre temporali consentono un confronto controllato tra

¹Il codice relativo al framework sviluppato è disponibile all'indirizzo: <https://github.com/MaryBug/Thesis-project>.



Figura 4.1: Framework proposto per l’analisi clinica del parlato e del dolore.

segmenti di durata prefissata, mentre i turni reali preservano maggiormente la struttura spontanea dell’interazione clinica. Le caratteristiche interpretabili permettono di descrivere proprietà acustiche e prosodiche direttamente leggibili, mentre gli embedding profondi consentono di esplorare informazione distribuita non definita a priori. Il confronto tra queste rappresentazioni non mira quindi a individuare a priori un approccio “migliore”, ma a verificare quali aspetti del parlato risultino stabili e quali mostrino un’eventuale relazione con le variabili cliniche.

4.1 Input clinico e audio

Dataset e variabili cliniche Il dataset iniziale comprende 93 registrazioni cliniche. Una registrazione viene esclusa dopo la revisione dei ruoli perché l’identificazione del paziente rimane incerta; il dataset finale contiene quindi **92 registrazioni relative a 90 pazienti**. Per ogni acquisizione vengono mantenuti separati identificativo del paziente e identificativo della registrazione. Le variabili cliniche considerate sono Numeric Rating Scale (NRS), Brief Pain Inventory (BPI) e Douleur Neuropathique en 4 Questions (DN4). Nelle analisi non supervisionate queste variabili non partecipano alla costruzione dei cluster e vengono introdotte soltanto successivamente. Nelle analisi supervisionate costituiscono invece il target, mantenendo sempre la separazione patient-level tra training e test. La BPI severity continua

è calcolata come media degli item `bpi3`–`bpi6`, mentre la BPI interference è ottenuta come media degli item `bpi9a`–`bpi9g`, richiedendo in entrambi i casi la disponibilità completa degli item. Per le analisi multiclass, le soglie vengono definite a priori sulla base di suddivisioni già adottate in letteratura e non sono ricavate empiricamente dal dataset considerato. La NRS viene suddivisa nelle classi 0–3, 4–7 e 8–10, secondo la classificazione impiegata da Sheikh et al. [32]. Per la BPI severity viene utilizzato l’item *worst pain* `bpi3`: Serlin et al. hanno individuato le classi 1–4, 5–6 e 7–10 per distinguere dolore lieve, moderato e severo [33]. Nel presente lavoro il punteggio 0, che indica assenza di dolore, viene incluso nella classe inferiore, ottenendo quindi gli intervalli 0–4, 5–6 e 7–10. Infine, la BPI interference viene suddivisa nelle classi < 2 , 2–5 e > 5 , corrispondenti ai cut-off individuati da Shi et al. sulla media dei sette item di interferenza [34]. Il DN4 viene analizzato anche in forma binaria adottando il cut-off proposto nello studio originale di sviluppo e validazione dello strumento [5]:

$$y_p = \mathbb{I}(DN4_p \geq 4), \quad (4.1.1)$$

dove p identifica il paziente, $DN4_p \in [0, 10]$ è il relativo punteggio e $\mathbb{I}(\cdot)$ è la funzione indicatrice, che vale 1 quando la condizione tra parentesi è vera e 0 altrimenti. Pertanto, $y_p \in \{0, 1\}$: $y_p = 1$ corrisponde a $DN4_p \geq 4$ e indica uno screening positivo per una possibile componente neuropatica, mentre $y_p = 0$ corrisponde a $DN4_p < 4$ e indica uno screening negativo. Nello studio originale, il cut-off di 4 punti su 10 ha mostrato una sensibilità dell’82.9% e una specificità dell’89.9% nella distinzione tra dolore neuropatico e non neuropatico. Il risultato viene comunque interpretato come esito di uno strumento di screening e non come diagnosi clinica autonoma. Le tre misure vengono mantenute distinte perché descrivono dimensioni differenti del fenomeno doloroso. NRS rappresenta principalmente l’intensità riferita, BPI include anche l’impatto funzionale, mentre DN4 è orientato allo screening di una possibile componente neuropatica. Questa distinzione è importante anche dal punto di vista sperimentale: una rappresentazione vocale che non risulti informativa rispetto a uno score potrebbe, almeno in principio, contenere informazione relativa a un’altra dimensione clinica. Per questo motivo le analisi iniziali vengono estese a NRS e BPI, mentre gli approfondimenti successivi sulle rappresentazioni profonde turn-level vengono concentrati sul DN4 binario.

4.2 Diarizzazione e identificazione del paziente

Poiché le interviste contengono più interlocutori, gli intervalli di parlato vengono identificati mediante `pyannote/speaker-diarization-community-1` [35]. L’audio viene

convertito in floating point e ricampionato a 16 kHz quando necessario. Le etichette prodotte dalla diarizzazione distinguono i parlanti ma non ne identificano il ruolo, per cui è richiesta una fase successiva di revisione.

Selezione del canale canonico Per le registrazioni stereo o multicanale viene selezionato un solo canale canonico, evitando di trattare canali della stessa intervista come osservazioni indipendenti. La selezione iniziale considera numero di parlanti, qualità del segnale, rapporto segnale-rumore, clipping e copertura temporale; i casi anomali vengono verificati manualmente.

Identificazione del parlante paziente Per associare le etichette della diarizzazione ai ruoli conversazionali vengono generate brevi anteprime audio a partire dai segmenti più lunghi dei parlanti. Sulle 93 registrazioni iniziali sono state prodotte 197 anteprime, trascritte mediante Faster-Whisper e utilizzate come supporto alla revisione manuale. I ruoli finali sono `paziente`, `medico_altro` e `incerto`. Più etichette di diarizzazione possono essere ricondotte allo stesso paziente. Una registrazione viene esclusa per ruolo non determinabile; tutte le 92 registrazioni finali contengono almeno un intervallo attribuito al paziente. Questa fase costituisce un passaggio metodologico centrale, poiché tutte le analisi successive devono riferirsi esclusivamente al parlato del paziente. Un errore nell'assegnazione dei ruoli propagherebbe infatti informazione proveniente dal medico o da altri interlocutori nelle rappresentazioni utilizzate per il clustering e la classificazione. La revisione dei casi ambigui viene quindi preferita a un'assegnazione completamente automatica, accettando l'esclusione della registrazione non risolvibile pur di mantenere maggiore affidabilità nell'identificazione del soggetto.

4.3 Costruzione delle unità di analisi

Ramo Whisper: segmentazione temporale Per il primo ramo, ciascuna registrazione viene suddivisa in finestre complete e non sovrapposte con durata:

$$T \in \{10, 20, 30\} \text{ s.} \quad (4.3.1)$$

Prima di applicare soglie sul parlato del paziente vengono generate 3028 finestre da 10 secondi, 1495 da 20 secondi e 976 da 30 secondi, per un totale di 5499 finestre.

Quantificazione del parlato del paziente Per ogni finestra W_j viene calcolato il rapporto tra durata complessiva del parlato del paziente e durata della finestra:

$$r_j = \frac{d_{\text{patient}}(W_j)}{T}. \quad (4.3.2)$$

dove j è l'indice della finestra e W_j identifica la j -esima finestra temporale. Il termine $d_{\text{patient}}(W_j)$ rappresenta, in secondi, la durata complessiva del parlato del paziente contenuto nella finestra, mentre $T \in \{10, 20, 30\}$ s è la durata nominale della finestra. Poiché $0 \leq d_{\text{patient}}(W_j) \leq T$, il rapporto assume valori $r_j \in [0, 1]$. Il valore 0 indica l'assenza di parlato del paziente, mentre il valore 1 indica che l'intera finestra è occupata dal suo parlato. Una soglia τ stabilisce quindi la quota minima richiesta per conservare la finestra, secondo la condizione $r_j \geq \tau$.

Sono analizzate soglie $\tau \in \{0.10, 0.20, 0.30, 0.40, 0.50\}$. Per ciascuna combinazione tra durata e soglia vengono valutati numero di finestre e numero di pazienti mantenuti.

Analisi di sensitività e configurazione finale La configurazione finale utilizza finestre da 10 secondi con:

$$r_j \geq 0.30, \quad (4.3.3)$$

corrispondenti ad almeno 3 secondi complessivi di parlato del paziente. Questa scelta preserva tutti i 90 soggetti e viene adottata per l'analisi definitiva degli embedding; le altre configurazioni rimangono come controllo di sensitività. La soglia non viene quindi scelta esclusivamente massimizzando il numero di finestre. Una soglia troppo bassa aumenterebbe il contributo di silenzio e parlato di altri interlocutori, mentre una soglia più elevata ridurrebbe progressivamente il numero di soggetti disponibili. La configurazione selezionata conserva l'intero campione patient-level e garantisce allo stesso tempo una quantità minima non trascurabile di parlato del paziente all'interno di ogni clip. L'analisi delle altre durate e soglie permette di verificare che la scelta non dipenda da una singola configurazione arbitraria.

Ramo turn-level: ricostruzione dei turni vocali Il secondo ramo utilizza i turni vocali reali del paziente. Due frammenti consecutivi vengono uniti quando il gap è ≤ 0.25 s e non interviene `medico_altro`. La procedura ricostruisce 4625 turni. Quelli di durata inferiore a 0.5 s vengono mantenuti per timeline e controlli di qualità ma esclusi dall'estrazione completa delle caratteristiche, lasciando **3825 turni validi**. Quando il turno precedente appartiene al personale sanitario viene inoltre calcolata la latenza di risposta, utilizzata come informazione contestuale e non come indicatore clinico autonomo.

4.4 Estrazione delle rappresentazioni

Embedding Whisper-small su finestre fisse Per ciascuna finestra selezionata viene utilizzato `openai/whisper-small`. L'audio a 16 kHz viene trasformato nella rappresentazione log-Mel prevista dal modello, descritta nella Sezione 3.3, e successivamente fornito all'encoder. Per ogni clip l'output è una sequenza di vettori di dimensionalità 768, che deve essere aggregata nel tempo.

Controllo dell'effetto del padding Poiché Whisper gestisce input fino a 30 secondi, le finestre più brevi vengono completate mediante padding. Sono confrontate due strategie: la media su tutte le posizioni (`FULL`) e la media sulle sole posizioni corrispondenti al segnale effettivo (`VALID-ONLY`). Quest'ultima è definita come:

$$\mathbf{e}_j = \frac{\sum_t m_{jt} \mathbf{H}_{jt}}{\sum_t m_{jt}}, \quad \mathbf{e}_j \in \mathbb{R}^{768}, \quad (4.4.1)$$

dove j identifica la clip considerata e t la posizione temporale nell'output dell'encoder. Il vettore $\mathbf{H}_{jt} \in \mathbb{R}^{768}$ rappresenta l'output prodotto da Whisper per la posizione t della clip j . Le sue 768 componenti assumono valori reali, positivi, negativi o nulli, e non possiedono singolarmente un significato acustico o clinico direttamente interpretabile. La variabile $m_{jt} \in \{0, 1\}$ è la maschera associata alla posizione t : vale 1 quando la posizione corrisponde al segnale audio effettivo e 0 quando deriva dal padding. Il numeratore somma quindi soltanto i vettori delle posizioni valide, mentre il denominatore $\sum_t m_{jt}$ ne indica il numero complessivo ed è sempre maggiore di zero per le clip considerate. Il vettore risultante $\mathbf{e}_j \in \mathbb{R}^{768}$ è la media delle rappresentazioni valide e costituisce l'embedding complessivo della clip. Anche le sue componenti sono valori reali non vincolati a un intervallo prestabilito. L'embedding viene interpretato nel suo insieme e utilizzato nelle successive analisi di clustering e classificazione. Le analisi diagnostiche mostrano che la strategia `FULL`, includendo le posizioni di padding, può produrre una struttura fortemente dipendente dalla durata. Tutte le analisi definitive usano quindi `VALID-ONLY` per ricondurre l'embedding al solo segnale disponibile e limitare gli effetti spurii della durata artificiale dell'input. Nelle visualizzazioni diagnostiche sulla durata viene inoltre limitato il numero di clip per paziente, senza modificare il dataset finale.

Aggregazione e analisi patient-level Per la configurazione 10 s / 30%, gli embedding validi di ciascun paziente vengono mediati e successivamente normalizzati L2, ottenendo un unico vettore patient-level da 768 dimensioni. PCA e UMAP vengono utilizzate soltanto

a scopo esplorativo. Come verifica supervisionata complementare, gli embedding patient-level vengono utilizzati per classificare il DN4 binario mediante regressione logistica con regolarizzazione L2 e bilanciamento delle classi. La valutazione impiega Stratified 5-Fold Cross-Validation con predizioni out-of-fold e un permutation test con 1000 permutazioni della ROC-AUC.

Caratteristiche acustiche, prosodiche e comportamentali Le caratteristiche vengono estratte su audio a 16 kHz e descrivono più aspetti della produzione vocale. La frequenza fondamentale viene stimata mediante `librosa.pyin` [36] nell'intervallo 75–300 Hz, ricavando statistiche di posizione e variabilità. L'energia è rappresentata mediante statistiche RMS; dalle regioni attive individuate con `librosa.effects.split` vengono inoltre calcolati rapporto di attività vocale, pause interne e rapporto parlato/silenzio. La componente spettrale comprende 13 MFCC, centroide, rolloff, bandwidth, flatness, zero-crossing rate e spectral contrast. La qualità della fonazione viene descritta mediante HNR, jitter e shimmer calcolati con Parselmouth/Praat [37]. Sono conservate anche variabili tecniche come durata, picco di ampiezza e clipping ratio.

Arricchimento ASR e fluidità I turni vengono trascritti mediante Faster-Whisper small. Dalle trascrizioni vengono estratti numero di parole, filler, ripetizioni adiacenti, parole al secondo, articulation rate, filler rate e repetition rate. Nella profilazione generale queste variabili descrivono la dinamica del parlato; il contenuto testuale viene utilizzato esplicitamente soltanto nell'analisi pain-related descritta nella Sezione 4.5.

Rappresentazioni profonde turn-level e multimodali Le rappresentazioni aggiuntive vengono estratte dai 3710 turni con trascrizione disponibile, mantenendo tutti i 90 pazienti. Il passaggio ai turni reali elimina il vincolo delle finestre prefissate e permette di confrontare, sulla stessa unità conversazionale, informazione audio, testuale e multimodale. Whisper e Wav2Vec2 rappresentano il segnale audio mediante encoder pre-addestrati con obiettivi differenti, MiniLM descrive il contenuto della trascrizione e la fusione audio-testo combina le due modalità.

Whisper-small, MiniLM ed early fusion Whisper-small viene applicato direttamente ai turni reali con pooling sulle sole posizioni valide, ottenendo embedding da 768 dimensioni. I sei turni superiori a 30 secondi vengono suddivisi in chunk e ricomposti mediante media pesata per durata. Le trascrizioni vengono codificate mediante il modello

sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2, ottenendo embedding testuali da 384 dimensioni. Questa rappresentazione viene introdotta per separare, almeno a livello analitico, il contenuto linguistico dal modo in cui il contenuto viene pronunciato. Se audio e testo catturassero aspetti complementari, una loro combinazione potrebbe risultare più informativa delle singole modalità. Audio e testo vengono normalizzati L2 e combinati mediante early fusion con contributo equivalente:

$$\mathbf{e}^{(f)} = \left[\frac{1}{\sqrt{2}} \mathbf{e}^{(a)}; \frac{1}{\sqrt{2}} \mathbf{e}^{(t)} \right], \quad (4.4.2)$$

ottenendo un vettore da 1152 dimensioni.

Embedding Wav2Vec2 Gli stessi 3710 interventi vocali vengono rappresentati mediante facebook/wav2vec2-base. L'ultimo hidden state viene mediato sulle posizioni valide, producendo vettori da 768 dimensioni; i turni superiori a 30 secondi vengono trattati con la stessa strategia di chunking e media pesata. Wav2Vec2 viene introdotto come controllo rispetto a Whisper perché i due modelli condividono l'uso di un encoder contestuale, ma differiscono per obiettivo di pre-addestramento. Whisper è ottimizzato nel contesto di compiti di riconoscimento e traduzione del parlato, mentre Wav2Vec2 apprende rappresentazioni tramite pre-training self-supervised sul segnale audio. Utilizzare entrambi permette quindi di verificare se le strutture osservate siano specifiche dell'encoder Whisper oppure emergano anche con una rappresentazione acustica appresa secondo un paradigma differente. Il clustering utilizza il medesimo campione bilanciato di 2156 turni, PCA al 95% della varianza e confronto tra K-Means, GMM, Ward e HDBSCAN. La stabilità viene verificata su 20 ricampionamenti; l'effetto della durata viene controllato confrontando le distribuzioni temporali tra i cluster mediante test di Kruskal-Wallis e quartili di durata.

4.5 Analisi e interpretazione clinica

Profilazione non supervisionata dei turni La profilazione acustica parte da 19 caratteristiche. Il preprocessing comprende winsorization al 1° e 99° percentile, trasformazione $\log_{1p}$ per le variabili fortemente asimmetriche, imputazione mediante mediana, RobustScaler e rimozione delle feature con correlazione di Spearman assoluta superiore a 0.90. L'insieme finale contiene 14 caratteristiche rappresentative di attività vocale, pause, prosodia, energia, fonazione, spettro e fluidità. Per evitare che pazienti con molti turni dominino il fit viene utilizzato un campione bilanciato con massimo 25 turni per soggetto. K-Means viene valutato

per $K = 2, \dots, 6$ mediante Silhouette score, Calinski–Harabasz e Davies–Bouldin, escludendo le soluzioni con cluster minimo inferiore all’8% del campione. La stabilità viene verificata su 20 inizializzazioni mediante Adjusted Rand Index (ARI). La soluzione selezionata viene infine applicata a tutti i 3825 turni. Il campionamento bilanciato viene utilizzato soltanto nella fase di stima della struttura dei cluster: una volta selezionata la soluzione, l’assegnazione viene estesa a tutti i turni disponibili. In questo modo la geometria iniziale non è determinata prevalentemente dai pazienti con conversazioni più lunghe, ma l’analisi finale conserva comunque l’intero dataset. La scelta del numero di cluster non viene inoltre basata su una singola metrica. Separazione geometrica, dimensione minima dei gruppi e stabilità rispetto a inizializzazioni differenti vengono considerate congiuntamente, perché una partizione apparentemente ben separata ma instabile sarebbe poco adatta alla successiva costruzione di profili patient-level.

Aggregazione patient-level Per ogni paziente viene calcolata la quota di turni assegnata a ciascun cluster:

$$q_{pk} = \frac{n_{pk}}{n_p}, \quad (4.5.1)$$

dove p identifica il paziente e k il cluster considerato. Il termine n_{pk} è il numero di interventi vocali del paziente p assegnati al cluster k , mentre n_p è il numero complessivo dei suoi interventi vocali. La quota q_{pk} assume valori nell’intervallo $[0, 1]$: valori prossimi a 0 indicano che il profilo è poco presente, mentre valori prossimi a 1 indicano che caratterizza quasi tutti gli interventi vocali del paziente. Per ciascun paziente vale inoltre $\sum_k q_{pk} = 1$.

insieme a cluster dominante, entropia e statistiche riassuntive utili all’interpretazione patient-level. Una seconda profilazione si concentra su sette variabili comportamentali e prosodiche: `speech_activity_ratio`, durata media delle pause interne, parole al secondo, filler rate, repetition rate, `f0_std` e `f0_iqr`. Il preprocessing e il campionamento bilanciato seguono la stessa logica; K viene valutato tra 2 e 5 e la stabilità è nuovamente misurata su 20 ripetizioni. Prima dell’interpretazione clinica vengono inoltre controllati possibili confondenti tecnici, tra cui durata dei turni, picco di ampiezza, clipping ratio, canale canonico e distribuzione dei cluster nelle registrazioni.

Associazione dei profili con gli score clinici Le quote dei cluster comportamentali vengono successivamente messe in relazione con DN4, NRS e BPI. Poiché le tre quote sommano a 1, nei modelli multivariati il cluster 1 viene utilizzato come riferimento e si impiegano q_{p0} e q_{p2} . Per il DN4 continuo vengono calcolate correlazioni di Spearman con correzione FDR e

un modello OLS composizionale con errori HC3; la significatività globale viene verificata tramite permutation test sull' R^2 con 5000 permutazioni. Per il DN4 binario vengono utilizzati test di Mann–Whitney e una regressione logistica patient-level valutata mediante Stratified 5-Fold Cross-Validation, permutation test e Repeated Stratified CV. NRS, BPI severity e BPI interference vengono analizzate in forma continua mediante correlazioni e OLS e in forma multiclass mediante Kruskal–Wallis e regressione logistica multinomiale. I confronti multipli vengono corretti con Benjamini–Hochberg; balanced accuracy e Macro-F1 vengono inoltre sottoposte a permutation test.

Classificazione supervisionata turn-level Per verificare se l'informazione presente nei singoli turni possa essere sfruttata direttamente, viene costruito un esperimento supervisionato sui 3825 turni con 72 caratteristiche candidate. I target sono DN4 binario, NRS, BPI severity e BPI interference nelle discretizzazioni definite nella Sezione 4.1. Questo esperimento è complementare all'analisi basata sulle quote dei cluster. Nel primo caso la descrizione patient-level deriva da una sintesi non supervisionata dei profili vocali; nel secondo, il modello utilizza direttamente le caratteristiche dei turni e apprende quali combinazioni siano maggiormente informative rispetto al target. Il confronto tra i due approcci permette quindi di verificare se un eventuale segnale clinico venga perso durante la discretizzazione in profili oppure se rimanga debole anche quando le feature originali sono utilizzate direttamente.

Cross-validation patient-level e prevenzione del leakage La valutazione utilizza Stratified 5-Fold Cross-Validation a livello paziente. In ogni fold, imputazione, rimozione delle feature con correlazione Pearson > 0.95 , pesatura dei campioni e feature selection vengono stimate esclusivamente sul training. La selezione mantiene le 20 caratteristiche con maggiore importanza secondo una Random Forest preliminare.

Random Forest e XGBoost. L'algoritmo Random Forest finale utilizza 1000 alberi, impostando `max_features=sqrt` e `min_samples_leaf=2`. XGBoost utilizza 400 stimatori, learning rate pari a 0.05, profondità massima 3, `min_child_weight=2`, `subsample=0.8`, `colsample_bytree=0.8`, regolarizzazione L2 pari a 1 e `tree_method=hist`.

La probabilità aggregata a livello di paziente è calcolata come media delle predizioni ottenute sui suoi singoli segmenti:

$$\hat{\pi}_p = \frac{1}{n_p} \sum_{i=1}^{n_p} \hat{\pi}_{pi}. \quad (4.5.2)$$

dove p identifica il paziente, i il singolo intervento vocale e n_p il numero complessivo di interventi disponibili per il soggetto. Il termine $\hat{\pi}_{pi}$ rappresenta la probabilità predetta per l'intervento i del paziente p , mentre $\hat{\pi}_p$ è la probabilità media ottenuta a livello paziente. Nel caso binario tali valori appartengono all'intervallo $[0, 1]$: valori maggiori indicano una maggiore probabilità di appartenenza alla classe positiva. Nel caso multiclass la stessa aggregazione viene applicata separatamente alla probabilità di ciascuna classe.

Le metriche vengono calcolate soltanto sui pazienti. Per XGBoost sul DN4 viene inoltre eseguito un permutation test con 1000 permutazioni, ricostruendo in ogni iterazione fold, preprocessing, feature selection e modello.

Multiple Instance Learning per il DN4 Per modellare direttamente il paziente come insieme di turni viene utilizzato un approccio Multiple Instance Learning. Ogni soggetto costituisce una bag di vettori da 72 feature. La motivazione è legata al disallineamento tra unità di osservazione e unità di etichetta: DN4 è disponibile per il paziente, mentre le feature vengono estratte da singoli turni. La media delle probabilità utilizzata nei modelli tradizionali attribuisce implicitamente la stessa importanza a tutte le osservazioni. Il MIL consente invece al modello di costruire una rappresentazione globale della bag e di assegnare pesi differenti ai turni, senza introdurre etichette artificiali a livello locale. Il preprocessing comprende imputazione e RobustScaler stimati esclusivamente sul training. Le bag vengono completate mediante zero-padding e una maschera impedisce alle posizioni artificiali di ricevere peso. La rete gated-attention proietta le instance in 64 dimensioni, calcola pesi di attenzione tramite due trasformazioni parallele a 32 dimensioni e costruisce una rappresentazione patient-level come somma pesata dei turni. La valutazione utilizza outer 5-Fold Cross-Validation. All'interno dell'outer training viene creato un validation split del 20% per scegliere il numero di epoche mediante early stopping; il modello finale viene poi riaddestrato da zero sull'intero outer training. L'esperimento viene ripetuto con cinque seed {42, 52, 62, 72, 82}.

Individuazione e analisi dei turni pain-related Dei 3825 turni validi, 3710 dispongono di una trascrizione utilizzabile. Su questi viene applicato un filtro rule-based conservativo, indipendente dagli score clinici, finalizzato a individuare riferimenti espliciti o contestualmente plausibili al dolore. Questa analisi segue una logica diversa rispetto agli esperimenti score-dependent. Invece di chiedere se il parlato permetta di predire un punteggio clinico complessivo, si restringe l'attenzione ai momenti nei quali il contenuto della conversazione riguarda direttamente il dolore. L'obiettivo è verificare se, all'interno dello stesso paziente,

tali turni presentino configurazioni vocali o comportamentali differenti rispetto al resto dell'intervista. La selezione viene mantenuta indipendente da NRS, BPI e DN4 per evitare che le etichette cliniche influenzino la definizione dei turni da confrontare. Il filtro considera termini e stem riconducibili a dolore, fastidio e descrittori sensoriali come bruciore, formicolio, fitte, scosse, crampi e oppressione; la parola *male* viene accettata soltanto in contesti specifici. Sono incluse alcune varianti ASR ad alta confidenza e vengono esclusi i casi compatibili con domande del medico o con dolore esplicitamente emotivo/psicologico. La procedura identifica **301 turni pain-related appartenenti a 80 pazienti**, pari all'8.11% dei turni trascritti.

Clustering dei pain-turn I 301 turni vengono analizzati mediante le stesse sette caratteristiche comportamentali e prosodiche della profilazione generale. Il fit utilizza un campione bilanciato con massimo cinque turni per paziente, pari a 253 osservazioni. K-Means viene valutato per $K = 2, \dots, 6$ e la scelta finale tiene conto sia delle metriche geometriche sia della stabilità su 20 ricampionamenti. La soluzione selezionata è poi applicata a tutti i 301 turni.

Confronto within-patient e duration matching Poiché i turni pain-related risultano mediamente più lunghi, il confronto con il resto della conversazione viene effettuato all'interno di ciascun paziente controllando la durata. A ogni intervento pain-related viene associato un intervento vocale di controllo, minimizzando la differenza assoluta di durata, con caliper massimo pari a 1 secondo e senza riutilizzare lo stesso controllo. La procedura produce 230 coppie. L'analisi primaria considera i 53 pazienti con almeno due coppie valide; una seconda analisi di sensibilità include i 74 pazienti con almeno una coppia. Per ciascuna delle sette caratteristiche vengono calcolate mediane patient-level, confrontate tramite Wilcoxon signed-rank test; gli effect size sono espressi mediante rank-biserial correlation e i p-value corretti con Benjamini–Hochberg.

Clustering delle rappresentazioni profonde e controllo della durata Le analisi aggiuntive utilizzano i 3710 turni con trascrizione disponibile, mantenendo tutti i 90 pazienti. Vengono confrontate rappresentazioni audio, testuali e multimodali. Questa estensione nasce dall'esigenza di verificare se le conclusioni ottenute con Whisper su finestre fisse e con le caratteristiche interpretabili dipendano dalla particolare rappresentazione adottata. Il passaggio ai turni reali elimina il vincolo delle finestre prefissate e permette di confrontare, sulla stessa unità conversazionale, differenti fonti di informazione. Whisper e Wav2Vec2 rappresentano il segnale audio attraverso encoder pre-addestrati con obiettivi differenti; MiniLM descrive in-

vece il contenuto della trascrizione; la fusione audio–testo verifica se le due modalità offrano informazione complementare. L'estensione ha inoltre una funzione di controllo metodologico. Poiché i turni reali hanno durata variabile, eventuali strutture latenti possono essere influenzate dalla quantità di segnale disponibile. Per questo la durata non viene trattata soltanto come variabile descrittiva, ma viene sottoposta ad audit specifici e successivamente utilizzata sia per residualizzare gli embedding sia come baseline supervisionata. In questo modo è possibile distinguere, per quanto consentito dal disegno sperimentale, un segnale legato alla geometria delle rappresentazioni da un segnale riconducibile prevalentemente alla struttura temporale della conversazione.

Clustering delle rappresentazioni profonde e controllo della durata Audio Whisper, testo e fusion vengono confrontati sullo stesso campione bilanciato di 2156 turni, con massimo 25 per paziente. Per ciascuna rappresentazione viene applicata PCA al 95% della varianza e vengono confrontati K-Means, GMM, Ward e HDBSCAN. K-Means, GMM e Ward sono valutati per più numeri di cluster, mentre HDBSCAN viene esplorato variando `min_cluster_size`. La stabilità è stimata su 20 ricampionamenti mediante ARI. Poiché il clustering Whisper audio mostra una forte relazione con la durata, viene effettuata un'analisi di sensitività residualizzando ciascuna dimensione dell'embedding rispetto a $\log(1 + d)$ e al relativo termine quadratico. PCA e clustering vengono quindi ripetuti sui residui, così da verificare quanta parte della struttura persista dopo il controllo del fattore temporale. La residualizzazione è un audit della rappresentazione, non una correzione definitiva del dato. Se la partizione resta simile, rimossa la componente prevedibile dalla durata, la struttura è in parte indipendente da tale variabile. Al contrario, una marcata riduzione di separazione o stabilità indica un contributo sostanziale della durata alla geometria iniziale degli embedding. Lo stesso controllo viene considerato anche per le rappresentazioni testuali e multimodali, così da mantenere confrontabile il disegno sperimentale.

Classificazione score-dependent degli embedding Sul DN4 binario vengono confrontate cinque rappresentazioni: Wav2Vec2, Whisper turn-level, MiniLM, fusion audio–testo e una baseline costituita da $\log(1 + d)$. L'inclusione della baseline temporale è essenziale per interpretare correttamente le prestazioni degli embedding. Poiché l'audit non supervisionato evidenzia una relazione tra durata e geometria di alcune rappresentazioni, un modello basato esclusivamente sulla durata consente di stimare quanto segnale discriminativo possa essere ottenuto senza utilizzare informazione acustica o linguistica ad alta dimensionalità.

Un eventuale vantaggio degli embedding deve quindi essere letto anche rispetto a questa baseline semplice. La valutazione utilizza Stratified 5-Fold Cross-Validation patient-level. Nei quattro spazi ad alta dimensionalità, la PCA al 95% viene adattata esclusivamente sui turni di training. Per compensare il diverso numero di turni per paziente, i campioni ricevono un peso inversamente proporzionale al numero di turni del soggetto. Random Forest e XGBoost producono probabilità turn-level successivamente mediate a livello paziente. Gli iperparametri vengono mantenuti fissi nei fold. Poiché la baseline duration-only mostra il segnale più marcato, XGBoost viene inoltre sottoposto a permutation test con 1000 permutazioni, ricostruendo i fold a ogni iterazione.

Multiple Instance Learning sugli embedding Wav2Vec2 Gli embedding Wav2Vec2 vengono infine usati in un secondo modello Attention-based MIL. Ogni paziente costituisce una bag con tutti i propri turni; nei fold di training si applica la PCA al 95% della varianza. L'esperimento verifica se la debolezza dei classificatori basati sulla media delle probabilità dipenda dalla strategia di aggregazione: anziché sintetizzare a posteriori le predizioni turn-level, il modello apprende direttamente la rappresentazione della bag e pesa i turni più informativi. La scelta di Wav2Vec2 è motivata anche dalla stabilità nel clustering non supervisionato, per verificare se un modello patient-level più flessibile possa sfruttarne la struttura. L'instance encoder proietta gli embedding in 64 dimensioni e un meccanismo di attenzione a 32 dimensioni pesa i turni prima della classificazione patient-level. Il modello è addestrato con Adam, learning rate 10^{-3} , weight decay 10^{-4} , dropout 0.20 e 60 epoche. Per ciascun fold si eseguono tre addestramenti con seed differenti, mediando le probabilità finali.

Separazione tra analisi non supervisionate e supervisionate Un principio metodologico centrale separa la scoperta della struttura dei dati dalla valutazione clinica: NRS, BPI e DN4 non sono usati per costruire cluster, PCA, UMAP o selezionare turni pain-related, ma introdotti solo in analisi post-hoc o esperimenti esplicitamente supervisionati. In questi ultimi, tutti i turni dello stesso paziente restano nello stesso fold. Le trasformazioni dipendenti da dati o target (imputazione, scaling, PCA, filtraggio delle correlazioni, feature selection e selezione delle epoche) vengono adattate esclusivamente sul training set. Vista la numerosità patient-level del campione, i risultati hanno valore esplorativo e non di validazione diagnostica.

Il presente capitolo riassume i risultati ottenuti applicando il framework descritto nel Capitolo 4. Le analisi comprendono rappresentazioni Whisper-small su finestre temporali, caratteristiche acustiche e prosodiche turn-level, modelli supervisionati patient-level, Multiple Instance Learning, rappresentazioni profonde Whisper/Wav2Vec2/MiniLM e un'analisi indipendente dagli score clinici sui turni pain-related.

5.1 Setup di valutazione

Il dataset comprende 92 registrazioni valide di 90 pazienti. Nel ramo Whisper a finestre fisse si valutano durate di 10, 20 e 30 secondi e soglie di `patient_speech_ratio` tra il 10% e il 50%; la configurazione definitiva usa finestre da 10 secondi, almeno il 30% di parlato del paziente e pooling `VALID-ONLY`. Nel ramo turn-level si ricostruiscono 4625 turni: 3825 (durata ≥ 0.5 s) per l'estrazione completa delle caratteristiche e 3710 (con trascrizione) per le analisi profonde. Per il DN4 binario il campione include 44 pazienti con $DN4 < 4$ e 46 con $DN4 \geq 4$. Tutte le valutazioni supervisionate sono organizzate a livello paziente. La distinzione tra numero di turni e pazienti indipendenti è centrale: le osservazioni turn-level aumentano la ricchezza descrittiva del segnale, ma non equivalgono a soggetti indipendenti. Pertanto, le metriche supervisionate sono sempre calcolate a livello paziente e i risultati interpretati in chiave esplorativa.

5.2 Risultati quantitativi

In questa sezione sono presentati i risultati quantitativi ottenuti nei diversi rami del framework. L'analisi considera gli embedding Whisper-small estratti dalle finestre temporali, la profilazione dei turni, le associazioni con gli score clinici, i modelli supervisionati e le rappresentazioni profonde audio, testuali e multimodali. In tutte le analisi supervisionate il paziente viene mantenuto come unità indipendente di valutazione.

5.2.1 Analisi di sensitività e Whisper-small patient-level

Prima dell'applicazione delle soglie vengono generate 3028 finestre da 10 s, 1495 da 20 s e 976 da 30 s. La Tabella 5.1 mostra l'effetto della soglia sul numero di finestre e di pazienti mantenuti.

Soglia	10 s		20 s		30 s	
	Finestre (%)	Pazienti	Finestre (%)	Pazienti	Finestre (%)	Pazienti
10%	2493 (82.3%)	90	1322 (88.4%)	90	892 (91.4%)	90
20%	1961 (64.8%)	90	1096 (73.3%)	90	744 (76.2%)	89
30%	1543 (51.0%)	90	833 (55.7%)	88	555 (56.9%)	85
40%	1176 (38.8%)	89	592 (39.6%)	79	393 (40.3%)	69
50%	881 (29.1%)	86	406 (27.2%)	65	261 (26.7%)	54

Tabella 5.1: Analisi di sensitività per durata della finestra temporale e soglia minima di parlato del paziente.

La configurazione 10 s / 30% conserva 1543 finestre e tutti i 90 pazienti, fornendo il miglior compromesso tra quantità di parlato e copertura del campione. Come mostrato in Figura 5.1, l'aumento della soglia riduce rapidamente la disponibilità di dati, soprattutto per le finestre più lunghe. Le finestre da 10 secondi risultano quindi più robuste rispetto alla perdita di copertura patient-level: fino alla soglia del 30% tutti i soggetti rimangono rappresentati, mentre con durate maggiori la riduzione del campione inizia prima. Questo risultato supporta la scelta della configurazione finale non soltanto in termini di numero assoluto di finestre, ma soprattutto di conservazione dell'intera coorte.

Sugli embedding Whisper-small aggregati a livello paziente, la regressione logistica ottiene accuracy pari a 0.4889, balanced accuracy pari a 0.4881, precision pari a 0.5000, sensibilità pari a 0.5217, specificità pari a 0.4545 e F1-score pari a 0.5106. La ROC-AUC è 0.5400 e il permutation test con 1000 permutazioni produce $p = 0.3197$. Le metriche




Figura 5.1: Analisi di sensitività rispetto alla soglia minima di parlato del paziente.

risultano quindi prossime ai valori attesi per una classificazione casuale. In particolare, la balanced accuracy inferiore a 0.5 indica che il modello non riconosce in modo equilibrato le due classi, mentre la ROC-AUC mostra una capacità di ordinamento solo marginalmente superiore al caso. La curva riportata in Figura 5.2 rimane infatti prossima alla diagonale. Gli embedding Whisper-small aggregati a livello paziente non forniscono pertanto un segnale DN4 sufficientemente robusto.




Figura 5.2: Curva ROC out-of-fold della regressione logistica basata sugli embedding Whisper-small aggregati a livello paziente per la classificazione DN4 binaria.

La proiezione UMAP riportata in Figura 5.3 mostra una forte sovrapposizione tra le due classi DN4, coerentemente con le deboli prestazioni supervisionate. I punti associati a $DN4 < 4$ e $DN4 \geq 4$ occupano infatti ampie regioni comuni dello spazio proiettato e non formano gruppi visivamente separabili. La visualizzazione costituisce esclusivamente un controllo qualitativo e non viene utilizzata come criterio quantitativo di classificazione.




Figura 5.3: Proiezione UMAP degli embedding Whisper-small VALID-ONLY per la configurazione da 10 secondi, distinta in base alla classe DN4.

5.2.2 Profilazione acustica e comportamentale

La profilazione acustica viene condotta sui 3825 interventi vocali. Dopo il controllo delle ridondanze rimangono 14 caratteristiche e il clustering viene adattato su un campione bilanciato di 2164 interventi. Le soluzioni ottenute variando il numero di cluster tra 2 e 6 sono confrontate nella Tabella 5.2.

K	Silhouette	Calinski–Harabasz	Davies–Bouldin	Cluster minimo (%)
2	0.2039	412.1221	1.8957	24.26
3	0.1503	400.3438	1.9101	18.85
4	0.1408	367.8481	1.8062	16.08
5	0.1425	332.0607	1.7229	11.04
6	0.1394	309.1533	1.7136	5.64

Tabella 5.2: Confronto delle soluzioni K-Means per la profilazione acustica.

La soluzione con $K = 2$ presenta il Silhouette score più elevato (0.2039) e il maggiore indice di Calinski–Harabasz (412.1221), indicando il miglior compromesso tra compattezza e separazione dei gruppi. Con $K = 3, \dots, 6$, il Silhouette score rimane compreso tra 0.1394 e 0.1503 e l'indice di Calinski–Harabasz diminuisce progressivamente fino a 309.1533. Gli indici di Davies–Bouldin migliorano invece per $K = 4, \dots, 6$, poiché valori inferiori indicano partizioni migliori, ma tale vantaggio è accompagnato da una minore separazione complessiva e dalla progressiva riduzione del cluster più piccolo. In particolare, con $K = 6$ il cluster minimo rappresenta soltanto il 5.64% del campione e non soddisfa il criterio minimo dell'8% stabilito

nella metodologia. La soluzione con $K = 2$ mantiene invece il 24.26% delle osservazioni nel cluster più piccolo e presenta anche un’elevata stabilità rispetto alle diverse inizializzazioni, con ARI medio pari a 0.9762. Per queste ragioni viene selezionata come soluzione finale. Applicata all’intero dataset, la soluzione assegna 2888 interventi vocali al cluster 0 e 937 al cluster 1. La profilazione comportamentale e prosodica utilizza sette caratteristiche ed è adattata sul medesimo campione bilanciato di 2164 interventi vocali. Le soluzioni ottenute per $K = 2, \dots, 5$ sono confrontate nella Tabella 5.3.

K	Silhouette	Calinski–Harabasz	Davies–Bouldin	Cluster minimo (%)
2	0.3050	746.7095	1.4572	31.15
3	0.3206	697.1575	1.1690	14.33
4	0.2569	703.1121	1.2297	13.40
5	0.2603	667.2589	1.1578	5.04

Tabella 5.3: Confronto delle soluzioni K-Means per la profilazione comportamentale e prosodica.

La soluzione con $K = 3$ presenta il Silhouette score più elevato (0.3206) e il minore indice di Davies–Bouldin tra le configurazioni che soddisfano il criterio dimensionale (1.1690), indicando una separazione complessivamente migliore dei profili. La soluzione con $K = 2$ presenta un indice di Calinski–Harabasz più elevato (746.7095), ma un Silhouette score inferiore (0.3050) e un indice di Davies–Bouldin più alto (1.4572), indicativo di una minore separazione tra i gruppi. Con $K = 4$ il Silhouette score diminuisce a 0.2569 e l’indice di Davies–Bouldin aumenta a 1.2297, senza fornire un miglioramento rispetto a $K = 3$. La soluzione con $K = 5$ raggiunge il valore più basso di Davies–Bouldin (1.1578), ma genera un cluster contenente soltanto il 5.04% del campione e viene pertanto esclusa perché non soddisfa la soglia minima dell’8% definita nella metodologia. La soluzione con $K = 3$ costituisce quindi il miglior compromesso tra separazione geometrica, dimensione dei gruppi e stabilità, risultando perfettamente riproducibile rispetto alle inizializzazioni considerate (ARI pari a 1.0). Applicata all’intero dataset, assegna rispettivamente 603, 2307 e 915 interventi vocali ai tre cluster. Le due soluzioni sono rappresentate nelle proiezioni PCA di Figura 5.4. Nel pannello (a), relativo alle caratteristiche acustiche, i due gruppi risultano distinti soprattutto lungo la prima componente, ma presentano una zona di sovrapposizione, coerente con il Silhouette score pari a 0.2039. Nel pannello (b), i profili comportamentali e prosodici mostrano una separazione più evidente, sebbene non completa, coerentemente con il Silhouette score più elevato, pari a 0.3206. Le prime due componenti rappresentano rispettivamente il 45.07%

e il 64.16% della varianza, per cui la seconda proiezione conserva una quota maggiore dell'informazione originaria.




Figura 5.4: Proiezione PCA degli interventi vocali nello spazio delle caratteristiche acustiche e comportamentali-prosodiche.

Le due partizioni descrivono strutture differenti del parlato: l'ARI tra il clustering acustico e quello comportamentale/prosodico è pari a -0.0346 . Poiché un ARI prossimo a 0 indica una concordanza paragonabile a quella attesa per caso, il valore leggermente negativo evidenzia l'assenza di corrispondenza tra le due partizioni. Le caratteristiche acustiche generali e quelle comportamentali/prosodiche sembrano quindi catturare aspetti differenti della produzione vocale. La stabilità interna delle singole soluzioni non implica, tuttavia, che esse descrivano la stessa struttura o possiedano rilevanza clinica.

5.2.3 Associazione dei profili con DN4, NRS e BPI

Le quote patient-level dei tre profili comportamentali non mostrano associazioni robuste con il DN4. Le correlazioni di Spearman risultano prossime a zero e, dopo correzione FDR, nessun confronto è significativo. Il modello OLS composizionale presenta $R^2 = 0.0075$ e il permutation test sull' R^2 produce $p = 0.7219$. Anche la regressione logistica patient-level basata sulle quote dei cluster mostra prestazioni deboli, con ROC-AUC 0.3293 e balanced accuracy 0.3547. La distribuzione dei valori ottenuti mediante Repeated Stratified 5-Fold Cross-Validation è mostrata in Figura 5.5. La ROC-AUC media è pari a 0.3821 ± 0.1038 , quindi inferiore al valore di riferimento 0.5 e caratterizzata da una variabilità elevata tra i fold. Sebbene alcune valutazioni superino occasionalmente 0.5, la maggior parte dei valori rimane al di sotto di tale soglia. Il modello non mostra pertanto una capacità discriminativa

stabile e la direzione dell'associazione non risulta riproducibile nelle diverse suddivisioni del campione.




Figura 5.5: Distribuzione delle ROC-AUC ottenute mediante Repeated Stratified 5-Fold Cross-Validation sul DN4 binario utilizzando le quote dei profili comportamentali.

L'estensione a NRS e BPI conduce allo stesso quadro generale, come sintetizzato nella Tabella 5.4.

Target	R^2	BA	Macro-F1	p_{BA}
NRS	0.0058	0.4266	0.3733	0.1029
BPI severity	0.0127	0.4352	0.3055	0.1029
BPI interference	0.0120	0.1933	0.1918	0.9860

Tabella 5.4: Associazione tra quote dei profili comportamentali e NRS/BPI

Per NRS il modello presenta $R^2 = 0.0058$, indicando che le quote dei profili spiegano meno dell'1% della variabilità dello score. La balanced accuracy è 0.4266 e il Macro-F1 è 0.3733. Sebbene la balanced accuracy sia superiore al valore casuale di circa 0.33 previsto per tre classi, il permutation test non raggiunge la significatività ($p_{BA} = 0.1029$). Per BPI severity si ottiene $R^2 = 0.0127$, corrispondente a circa l'1.3% di varianza spiegata. La balanced accuracy è 0.4352 e il Macro-F1 è 0.3055; anche in questo caso il risultato non è significativo ($p_{BA} = 0.1029$). Il valore relativamente più alto della balanced accuracy non è quindi accompagnato da una classificazione sufficientemente uniforme delle tre classi. BPI interference presenta $R^2 = 0.0120$, balanced accuracy pari a 0.1933 e Macro-F1 pari a 0.1918. Entrambe le metriche di classificazione sono inferiori al livello casuale atteso per tre classi e il permutation test produce $p_{BA} = 0.9860$. Nel complesso, le quote dei profili non mostrano associazioni robuste con nessuno dei tre target. Una possibile spiegazione è il disallineamento tra i profili, costruiti a partire dai singoli turni, e gli score clinici, che descrivono una condizione complessiva del paziente. Anche la numerosità limitata del campione e la discretizzazione in tre classi

possono ridurre la capacità di individuare associazioni deboli. Nessuna delle tre dimensioni mostra quindi un’associazione patient-level robusta con le quote dei profili. Questo risultato mostra che la presenza di cluster stabili non si traduce automaticamente in una stratificazione clinica. I profili descrivono modalità ricorrenti di produzione vocale, ma le loro proporzioni patient-level non risultano sistematicamente associate né all’intensità del dolore, né alla sua interferenza, né allo screening DN4.

5.2.4 Classificazione turn-level con Random Forest e XGBoost

Random Forest e XGBoost vengono valutati sulle 72 caratteristiche turn-level, aggregando le probabilità a livello paziente. I risultati sono riportati nella Tabella 5.5.

Sul DN4 entrambi i modelli ottengono risultati superiori al livello casuale. La Random Forest raggiunge balanced accuracy 0.5761, F1-score 0.6122 e ROC-AUC 0.5731, mentre XGBoost ottiene i valori migliori, con balanced accuracy 0.5988, F1-score 0.6250 e ROC-AUC 0.6117. Il permutation test di XGBoost non raggiunge tuttavia la significatività né per la balanced accuracy ($p_{BA} = 0.0769$) né per la ROC-AUC ($p_{AUC} = 0.0829$). Per NRS le prestazioni sono inferiori al livello casuale atteso per tre classi: la balanced accuracy è 0.2619 per Random Forest e 0.2753 per XGBoost, mentre le ROC-AUC sono rispettivamente 0.3815 e 0.3991. Le caratteristiche considerate non permettono quindi di distinguere adeguatamente le classi di intensità del dolore. Per BPI severity la Random Forest raggiunge balanced accuracy 0.3611, F1-score 0.3179 e ROC-AUC 0.4775. XGBoost ottiene balanced accuracy 0.3204, F1-score 0.3138 e ROC-AUC 0.4704. Le prestazioni rimangono pertanto prossime al caso. BPI interference presenta i risultati più deboli. La Random Forest ottiene balanced accuracy 0.3088 e ROC-AUC 0.4300, mentre XGBoost raggiunge rispettivamente 0.2513 e 0.4074. I valori non indicano una capacità discriminativa utile. Il comportamento relativamente migliore sul DN4 può dipendere dalla formulazione binaria del target, che lascia un numero maggiore di pazienti per classe rispetto alle discretizzazioni multiclass di NRS e BPI. Inoltre, le caratteristiche vocali potrebbero rappresentare alcune differenze associate alla componente neuropatica più efficacemente dell’intensità o dell’interferenza del dolore. Questa rimane tuttavia un’ipotesi esplorativa, poiché il permutation test non conferma la significatività del risultato.

Il risultato relativamente migliore tra le caratteristiche interpretabili si osserva sul DN4 con XGBoost, ma il permutation test non raggiunge significatività ($p_{BA} = 0.0769$, $p_{AUC} = 0.0829$). NRS e BPI mostrano prestazioni più deboli. Pur non raggiungendo la soglia convenzionale di significatività, il DN4 rappresenta quindi il target per il quale le caratteristiche turn-level mostrano il segnale descrittivamente più marcato. Questo andamento non viene osservato

Target	Modello	BA	F1	ROC-AUC
DN4	Random Forest	0.5761	0.6122	0.5731
	XGBoost	0.5988	0.6250	0.6117
NRS	Random Forest	0.2619	0.2449	0.3815
	XGBoost	0.2753	0.2653	0.3991
BPI severity	Random Forest	0.3611	0.3179	0.4775
	XGBoost	0.3204	0.3138	0.4704
BPI interference	Random Forest	0.3088	0.2772	0.4300
	XGBoost	0.2513	0.2517	0.4074

Tabella 5.5: Prestazioni patient-level dei modelli Random Forest e XGBoost

con la stessa intensità per NRS o BPI, suggerendo che le diverse dimensioni cliniche non siano ugualmente rappresentate dalle feature vocali considerate.

Multiple Instance Learning. Il modello MIL basato sulle 72 caratteristiche turn-level produce balanced accuracy media pari a 0.4982 ± 0.0192 e ROC-AUC pari a 0.5308 ± 0.0174 . I risultati rimangono quindi prossimi al livello casuale e sono inferiori a quelli ottenuti da XGBoost sulle stesse caratteristiche, che raggiunge balanced accuracy 0.5988 e ROC-AUC 0.6117. Il meccanismo di gated attention permette teoricamente di assegnare un peso maggiore ai turni più informativi. Nel campione considerato, tuttavia, tale flessibilità non produce un miglioramento misurabile. Una possibile motivazione è la disponibilità di soli 90 pazienti, che costituiscono le bag indipendenti effettivamente utilizzabili per l'addestramento, a fronte di una rappresentazione composta da 72 caratteristiche e di un'elevata variabilità tra i turni dello stesso soggetto. Il risultato non dimostra che il MIL sia inadatto al problema, ma indica che, con la numerosità e le rappresentazioni disponibili, l'aumento della complessità del modello non compensa la debolezza del segnale patient-level.

5.2.5 Turni pain-related e confronto duration-matched

Dei 3710 interventi vocali trascritti, 301 sono identificati come pain-related e appartengono a 80 pazienti. Sul campione bilanciato di 253 interventi viene selezionata una soluzione a tre cluster, preferita a $K = 2$ per la maggiore stabilità rispetto al ricampionamento (ARI medio 0.9459 contro 0.8816). Il cluster 2, caratterizzato da parlato continuo e prosodicamente stabile, è il più frequente e comprende 127 interventi vocali appartenenti a 59 pazienti. Il cluster 1 comprende 109 interventi di 41 pazienti ed è associato a una minore continuità vocale,

mentre il cluster 0, caratterizzato da maggiore variabilità prosodica, raccoglie 65 interventi di 32 pazienti. Uno stesso paziente può presentare interventi appartenenti a cluster differenti; per questo il numero complessivo dei pazienti riportato nelle tre righe non corrisponde alla somma di soggetti distinti.

La numerosità e le caratteristiche descrittive dei profili individuati tra gli interventi vocali pain-related sono riportate nella Tabella 5.6.

Cluster	Profilo descrittivo	Turni	Pazienti
0	Alta variabilità prosodica	65	32
1	Bassa continuità vocale	109	41
2	Parlato continuo e prosodicamente stabile	127	59

Tabella 5.6: Profili comportamentali/prosodici dei turni pain-related

Il confronto pain/rest viene effettuato dopo matching within-patient sulla durata e produce 230 coppie. L’analisi primaria considera 53 pazienti con almeno due coppie valide; nessuna delle sette caratteristiche rimane significativa dopo correzione FDR. Anche l’analisi di sensibilità sui 74 pazienti con almeno una coppia conduce alla stessa conclusione. Prima del controllo della durata alcune variabili mostrano differenze nominali, ma tali segnali si attenuano dopo il matching e non sopravvivono alla correzione per confronti multipli. Il risultato suggerisce che parte delle differenze inizialmente osservabili tra pain-turn e resto della conversazione sia legata al fatto che i turni in cui il paziente parla del dolore tendono a essere più lunghi.

5.2.6 Clustering delle rappresentazioni profonde turn-level

Whisper-small, MiniLM e la fusion audio-testo vengono confrontati sullo stesso campione bilanciato di 2156 interventi vocali. I risultati prima e dopo il controllo della durata sono riportati nella Tabella 5.7. Il Silhouette score misura la separazione geometrica dei cluster nella singola partizione: valori prossimi a 1 indicano gruppi compatti e ben separati, mentre valori prossimi a 0 indicano sovrapposizione. L’ARI misura invece la stabilità della partizione tra ricampionamenti: un valore prossimo a 1 indica assegnazioni altamente riproducibili, mentre un valore prossimo a 0 indica una concordanza paragonabile al caso. La condizione “non controllata” utilizza gli embedding originali; quella “controllata” utilizza gli embedding residualizzati rispetto alla durata dell’intervento vocale.

Whisper presenta inizialmente la maggiore separazione geometrica (Silhouette 0.2404) e una stabilità quasi perfetta (ARI 0.9899). Tuttavia, i due cluster mostrano durate mediane

Rappresentazione	Condizione	Silhouette	ARI
Whisper (audio)	Non controllato	0.2404	0.9899
	Controllato	0.0512	0.6422
MiniLM (testo)	Non controllato	0.0785	0.9254
	Controllato	0.0655	0.8478
Fusion (audio+testo)	Non controllato	0.1103	0.9493
	Controllato	0.0444	0.0395

Tabella 5.7: Clustering K-Means a due gruppi prima e dopo il controllo della durata

molto differenti, rispettivamente 4.050 e 1.114 secondi, e una correlazione point-biserial con $\log(1 + d)$ pari a -0.8025 . Dopo il controllo della durata, il Silhouette score diminuisce a 0.0512 e l'ARI a 0.6422. La partizione rimane quindi parzialmente riproducibile, ma i cluster non risultano più geometricamente ben separati.

MiniLM presenta già prima del controllo una separazione debole: il Silhouette score passa da 0.0785 a 0.0655. L'ARI diminuisce soltanto da 0.9254 a 0.8478, mostrando che il modello continua a produrre una partizione stabile, ma scarsamente separata. Una struttura può quindi essere riproducibile senza identificare gruppi nettamente distinti.

La fusion audio–testo mostra il deterioramento più marcato: il Silhouette score passa da 0.1103 a 0.0444 e l'ARI da 0.9493 a 0.0395. Dopo la residualizzazione, la partizione perde quindi sia separazione sia stabilità. Nel complesso, il confronto mostra che la durata contribuisce in misura rilevante soprattutto alla struttura osservata negli embedding Whisper e nella rappresentazione multimodale.

Clustering Wav2Vec2 Sugli stessi 3710 turni, Wav2Vec2 produce una soluzione K-Means a due cluster con Silhouette 0.2048 e ARI medio 0.9764. I cluster contengono 1683 e 2027 turni e 89 pazienti su 90 presentano osservazioni in entrambi i gruppi. A differenza di Whisper, la durata non differisce significativamente tra i cluster (mediane 1.705 e 1.772 s; Kruskal–Wallis $p = 0.3771$). La struttura risulta quindi stabile e non principalmente determinata dalla durata, ma ciò non implica una relazione clinica. Questo confronto mostra che encoder differenti possono organizzare gli stessi turni secondo geometrie diverse. Il fatto che 89 pazienti su 90 presentino turni in entrambi i cluster suggerisce inoltre che la partizione Wav2Vec2 descriva soprattutto variabilità intra-paziente. La stabilità della struttura rimane quindi un risultato descrittivo e deve essere valutata separatamente rispetto al target clinico.

5.2.7 Classificazione delle rappresentazioni profonde

Whisper turn-level, Wav2Vec2, MiniLM, fusion e una baseline basata esclusivamente sulla durata vengono confrontati sul DN4 mediante Random Forest e XGBoost. I risultati sono riportati nella Tabella 5.8.

Rappresentazione	Modello	BA	F1	ROC-AUC
Wav2Vec2	Random Forest	0.4457	0.6260	0.4224
	XGBoost	0.4526	0.5243	0.4481
Whisper turn-level	Random Forest	0.5000	0.6765	0.5109
	XGBoost	0.5282	0.6250	0.4975
MiniLM testo	Random Forest	0.5124	0.6718	0.4807
	XGBoost	0.5815	0.6942	0.5543
Fusion audio–testo	Random Forest	0.5000	0.6765	0.5104
	XGBoost	0.4279	0.5487	0.4521
Durata	Random Forest	0.6275	0.7130	0.6695
	XGBoost	0.6052	0.6957	0.7134

Tabella 5.8: Prestazioni patient-level sul DN4 delle rappresentazioni profonde e della durata

Tra gli embedding audio, Wav2Vec2 non mostra capacità discriminativa: con Random Forest ottiene balanced accuracy 0.4457 e ROC-AUC 0.4224, mentre con XGBoost raggiunge rispettivamente 0.4526 e 0.4481. Whisper turn-level presenta valori leggermente superiori, ma ancora prossimi al caso: Random Forest ottiene balanced accuracy 0.5000 e ROC-AUC 0.5109, mentre XGBoost raggiunge 0.5282 e 0.4975. MiniLM con XGBoost fornisce il risultato relativamente migliore tra le rappresentazioni profonde, con balanced accuracy 0.5815, F1-score 0.6942 e ROC-AUC 0.5543. Con Random Forest, invece, la balanced accuracy è 0.5124 e la ROC-AUC è 0.4807. Il vantaggio di XGBoost suggerisce la possibile presenza di relazioni non lineari nel contenuto linguistico, ma la ROC-AUC ancora vicina a 0.5 indica che il segnale rimane modesto. La fusion audio–testo non migliora le singole modalità. Random Forest ottiene balanced accuracy 0.5000 e ROC-AUC 0.5104, mentre XGBoost scende rispettivamente a 0.4279 e 0.4521. La concatenazione aumenta la dimensionalità senza modellare esplicitamente le interazioni tra audio e testo; con soli 90 pazienti può quindi combinare informazione debole o ridondante senza produrre un vantaggio predittivo. La baseline basata sulla durata ottiene i risultati migliori. Random Forest raggiunge la balanced accuracy più alta, pari a 0.6275, con ROC-AUC 0.6695. XGBoost ottiene balanced accuracy 0.6052, F1-score 0.6957 e la ROC-AUC

più alta, pari a 0.7134. Il permutation test conferma il risultato di XGBoost, con $p_{AUC} = 0.001$ e $p_{BA} = 0.024$. L’audit patient-level non evidenzia tuttavia differenze significative nella durata mediana ($p = 0.3327$) o nel numero di turni ($p = 0.3225$), e la ROC-AUC della sola durata mediana è 0.5595. XGBoost potrebbe quindi sfruttare caratteristiche non lineari della distribuzione delle durate, anziché una semplice differenza tra le mediane dei gruppi. La durata deve essere interpretata come possibile fattore conversazionale o confondente da controllare e non come biomarcatore clinico autonomo.

Multiple Instance Learning su Wav2Vec2. L’Attention-based MIL sugli embedding Wav2Vec2 produce balanced accuracy out-of-fold 0.5109 e ROC-AUC 0.5262. Anche questa strategia rimane vicina alle prestazioni attese per caso e non evidenzia un segnale DN4 robusto. Il confronto con il precedente MIL basato sulle 72 caratteristiche turn-level conduce quindi a una conclusione coerente: cambiare la rappresentazione di input non è sufficiente, nel campione disponibile, a rendere efficace una strategia patient-level basata sull’attenzione.

5.3 Sintesi e discussione

La Tabella 5.9 mostra il confronto tra le strategie score-dependent applicate al DN4 binario. Il confronto evidenzia una distinzione tra stabilità dei cluster e capacità di discriminare il DN4. Whisper-small su finestre fisse ottiene balanced accuracy 0.4881 e ROC-AUC 0.5400, mentre le quote dei profili comportamentali raggiungono rispettivamente 0.3547 e 0.3293. Nessuno dei due approcci fornisce quindi una classificazione patient-level robusta. Le caratteristiche interpretabili turn-level mostrano risultati relativamente migliori. La Random Forest raggiunge balanced accuracy 0.5761 e ROC-AUC 0.5731, mentre XGBoost ottiene 0.5988 e 0.6117. Il permutation test non raggiunge tuttavia la significatività. Il MIL sulle stesse caratteristiche rimane vicino al caso, con balanced accuracy 0.4982 e ROC-AUC 0.5308, indicando che l’aggregazione mediante attenzione non recupera un segnale più forte. Tra gli embedding turn-level, Whisper con XGBoost raggiunge balanced accuracy 0.5282 e ROC-AUC 0.4975, Wav2Vec2 rispettivamente 0.4526 e 0.4481 e MiniLM 0.5815 e 0.5543. La fusion audio-testo ottiene 0.4279 e 0.4521 e non migliora quindi le singole modalità. Anche il MIL sugli embedding Wav2Vec2 rimane prossimo al caso, con balanced accuracy 0.5109 e ROC-AUC 0.5262. Questi risultati mostrano che la stabilità di una partizione non implica rilevanza clinica. La profilazione acustica presenta ARI 0.9762 ma Silhouette 0.2039, mentre quella comportamentale presenta ARI 1.0000 e Silhouette 0.3206. Wav2Vec2 produce analogamente

Approccio	Balanced Accuracy	ROC-AUC
<i>Baseline patient-level</i>		
Whisper 10 s patient-level + LR	0.4881	0.5400
Quote profili comportamentali + LR	0.3547	0.3293
<i>Feature turn-level aggregate</i>		
Feature turn-level + Random Forest	0.5761	0.5731
Feature turn-level + XGBoost	0.5988	0.6117
<i>Multiple Instance Learning</i>		
MIL su feature turn-level	0.4982	0.5308
MIL su Wav2Vec2	0.5109	0.5262
<i>Embedding turn-level</i>		
Whisper turn-level + XGBoost	0.5282	0.4975
Wav2Vec2 turn-level + XGBoost	0.4526	0.4481
MiniLM testo + XGBoost	0.5815	0.5543
Fusion audio-testo + XGBoost	0.4279	0.4521
<i>Durata del turno</i>		
Durata + Random Forest	0.6275	0.6695
Durata + XGBoost	0.6052	0.7134

Tabella 5.9: Confronto delle principali strategie score-dependent sul DN4 binario.

cluster stabili, con ARI 0.9764 e Silhouette 0.2048, senza tradursi in una buona classificazione del DN4. Whisper turn-level evidenzia inoltre il possibile effetto di un confondente: dopo il controllo della durata, il Silhouette score diminuisce da 0.2404 a 0.0512 e l'ARI da 0.9899 a 0.6422. Per la fusion l'ARI scende da 0.9493 a 0.0395. La struttura osservata negli embedding originali dipende quindi, almeno in parte, dalla durata dei turni. Il segnale supervisionato più marcato è prodotto dalla baseline temporale. Random Forest raggiunge balanced accuracy 0.6275 e ROC-AUC 0.6695, mentre XGBoost ottiene rispettivamente 0.6052 e 0.7134, con permutation test significativo. Tale risultato non viene interpretato come evidenza di un biomcatore, poiché la durata può riflettere il tipo di domanda, la struttura dell'intervista e le strategie conversazionali. Infine, i 301 turni pain-related formano profili comportamentali e prosodici riproducibili, ma il confronto duration-matched su 230 coppie non evidenzia differenze significative dopo la correzione FDR. Nel complesso, le rappresentazioni analizzate non possono essere considerate biomcatore diagnostici autonomi del dolore, ma i risultati mostrano la necessità di controllare esplicitamente durata, struttura conversazionale e variabilità patient-level.

5.4 Limiti dello studio

I risultati vanno interpretati alla luce di alcuni limiti del disegno sperimentale. Come sintetizzato nella Tabella 5.9, le caratteristiche interpretabili analizzate con XGBoost raggiungono una balanced accuracy (BA) di 0.5988 e una ROC-AUC di 0.6117, senza superare il permutation test ($p_{BA} = 0.0769$ e $p_{AUC} = 0.0829$). Tra le rappresentazioni profonde, MiniLM ottiene il risultato migliore (BA 0.5815, ROC-AUC 0.5543). I modelli MIL restano prossimi al caso: 0.4982 (BA) e 0.5308 (AUC) sulle caratteristiche turn-level, e 0.5109 (BA) e 0.5262 (AUC) sugli embedding Wav2Vec2. Il segnale più marcato proviene dalla baseline basata sulla durata: Random Forest ottiene BA 0.6275 e ROC-AUC 0.6695, mentre XGBoost raggiunge 0.6052 e 0.7134, con permutation test significativo ($p_{BA} = 0.024$ e $p_{AUC} = 0.001$). La durata è quindi un fattore confondente, poiché le sue prestazioni possono riflettere la struttura dell'intervista e le dinamiche conversazionali anziché una proprietà clinica propria del paziente.

Il primo limite riguarda la numerosità campionaria: pur includendo migliaia di finestre e turni, l'unità indipendente è il paziente ($N = 90$), il che limita l'addestramento e la validazione di modelli complessi. Inoltre, le registrazioni derivano da interviste cliniche reali e non da un protocollo vocale controllato. Ciò aumenta il realismo applicativo, ma introduce variabilità su durata, quantità di parlato, condizioni di acquisizione e interazione con il personale sanitario, spiegando il vantaggio della baseline temporale e impedendo interpretazioni cliniche o causali. Un ulteriore limite è il disallineamento tra il livello delle osservazioni (turni) e delle etichette (NRS, BPI e DN4 riferiti al paziente). La valutazione patient-level e il MIL attenuano il problema, ma non individuano quali turni esprimano l'informazione associata allo score clinico. Infine, Whisper-small, Wav2Vec2 e MiniLM sono stati utilizzati senza fine-tuning specifico sul dolore. Gli embedding testuali e l'individuazione dei turni pain-related dipendono inoltre dalla qualità delle trascrizioni automatiche e da un filtro lessicale non validato mediante un'annotazione manuale esaustiva. La cross-validation e i permutation test riducono il rischio di stime ottimistiche, ma non sostituiscono una validazione esterna su un campione indipendente.

Il dolore è un fenomeno complesso e multidimensionale, valutato principalmente mediante strumenti di self-report quali NRS, BPI e DN4. Sebbene fondamentali nella pratica clinica, tali strumenti possono essere affiancati da fonti complementari di informazione. Tra queste, il parlato può essere acquisito in modo non invasivo durante l'interazione clinica, ma la sua analisi richiede particolare attenzione ai fattori individuali, tecnici e conversazionali che possono influenzare il segnale.

La letteratura si concentra prevalentemente su campioni ridotti, soggetti sani, dolore acuto indotto e compiti controllati. Rimane invece meno studiato il parlato spontaneo prodotto durante interviste cliniche reali, caratterizzate dalla presenza di più interlocutori, da durate variabili e da contenuti non definiti a priori. Il presente lavoro ha affrontato questo divario analizzando congiuntamente caratteristiche vocali interpretabili, rappresentazioni profonde e informazioni testuali in un contesto clinico multi-parlante.

A tale scopo è stato sviluppato un framework applicato a 92 registrazioni relative a 90 pazienti. Dopo la diarizzazione e l'identificazione del parlante paziente, sono state costruite due unità di analisi: finestre temporali di durata controllata e interventi vocali reali. Da queste sono state estratte caratteristiche acustiche, prosodiche e comportamentali, embedding audio Whisper-small e Wav2Vec2, embedding testuali MiniLM e rappresentazioni multimodali ottenute mediante early fusion. Le rappresentazioni sono state esaminate attraverso clustering non supervisionato, modelli supervisionati con valutazione patient-level, Multiple Instance Learning e un'analisi specifica degli interventi vocali *pain-related*.

L'analisi di sensitività ha individuato come configurazione più adeguata le finestre da 10 secondi contenenti almeno il 30 % di parlato del paziente, preservando tutti i 90 soggetti. Gli embedding Whisper aggregati a livello paziente e i profili acustici e comportamentali non hanno mostrato associazioni robuste con DN4, NRS o BPI. Tra le caratteristiche interpretabili, XGBoost sul DN4 ha ottenuto il risultato relativamente migliore, con balanced accuracy pari a 0.5988 e ROC-AUC pari a 0.6117, senza tuttavia superare i permutation test. Le rappresentazioni profonde hanno mostrato una capacità discriminativa limitata: la stabilità dei cluster, particolarmente elevata per Wav2Vec2, non si è tradotta in rilevanza clinica.

Il segnale supervisionato più marcato è stato prodotto dalla baseline basata sulla durata degli interventi vocali. XGBoost ha raggiunto una ROC-AUC pari a 0.7134 e una balanced accuracy pari a 0.6052, con permutation test significativi. Tale risultato non costituisce evidenza di un biomcatore temporale, ma indica che la struttura dell'intervista e le dinamiche conversazionali possono agire come fattori confondenti. Analogamente, il confronto degli interventi *pain-related* con il resto della conversazione non ha evidenziato differenze robuste dopo il controllo della durata e la correzione per confronti multipli.

Nel complesso, i risultati non supportano l'impiego delle rappresentazioni considerate come strumenti diagnostici autonomi del dolore. Il principale contributo della tesi consiste nella definizione e nella valutazione critica di un framework riproducibile per trasformare interviste cliniche multi-parlante in rappresentazioni strutturate a livello di finestra, intervento vocale e paziente. Lo studio evidenzia inoltre la necessità di distinguere tra stabilità delle strutture individuate, capacità discriminativa e significato clinico.

Gli sviluppi futuri dovranno prevedere campioni più ampi, una validazione esterna e registrazioni longitudinali. Sarà inoltre necessario approfondire il ruolo della durata e delle altre proprietà dell'interazione, validare manualmente l'individuazione degli interventi *pain-related* e sperimentare il fine-tuning degli encoder e strategie multimodali capaci di modellare più efficacemente contenuto linguistico, produzione vocale e dinamica temporale.

- [1] S. N. Raja, D. B. Carr, M. Cohen, N. B. Finnerup, H. Flor, S. Gibson, F. J. Keefe, J. S. Mogil, M. Ringkamp, K. A. Sluka, X.-J. Song, B. Stevens, M. D. Sullivan, P. R. Tutelman, T. Ushida, and K. Vader, "The revised international association for the study of pain definition of pain: concepts, challenges, and compromises," *Pain*, vol. 161, no. 9, pp. 1976–1982, 2020.
- [2] M. J. Hjermstad, P. M. Fayers, D. F. Haugen, A. Caraceni, G. W. Hanks, J. H. Loge, R. Fainsinger, N. Aass, and S. Kaasa, "Studies comparing numerical rating scales, verbal rating scales, and visual analogue scales for assessment of pain intensity in adults: a systematic literature review," *Journal of Pain and Symptom Management*, vol. 41, no. 6, pp. 1073–1093, 2011.
- [3] A. Monticelli and B. V. Grootven, "Exploring established cut-off points for pain levels in the numeric rating scale: Insights from a literature overview," *Pain Management Nursing*, vol. 26, no. 6, pp. 689–695, 2025.
- [4] C. S. Cleeland and K. M. Ryan, "Pain assessment: global use of the brief pain inventory," *Annals of the Academy of Medicine, Singapore*, vol. 23, no. 2, pp. 129–138, 1994.
- [5] D. Bouhassira, N. Attal, H. Alchaar, F. Boureau, B. Brochet, J. Bruxelle, G. Cunin, J. Fermanian, P. Ginies, A. Grun-Overdyking, H. Jafari-Schluep, M. Lantéri-Minet, B. Laurent, G. Mick, A. Serrie, D. Valade, and É. Vicaut, "Comparison of pain syndromes associated with nervous or somatic lesions and development of a new neuropathic pain diagnostic questionnaire (DN4)," *Pain*, vol. 114, no. 1-2, pp. 29–36, 2005.

- [6] U. De Silva, S. Madanian, S. Olsen, J. M. Templeton, C. Poellabauer, S. L. Schneider, A. Narayanan, and R. Rubaiat, "Clinical decision support using speech signal analysis: Systematic scoping review of neurological disorders," *Journal of Medical Internet Research*, vol. 27, p. e63004, 2025.
- [7] L. M. L. Helmer, R. A. F. Weijenberg, R. de Vries, W. P. Achterberg, S. Lautenbacher, E. L. Sampson, and F. Lobbezoo, "Crying out in pain—a systematic review into the validity of vocalization as an indicator for pain," *European Journal of Pain*, vol. 24, no. 9, pp. 1703–1715, 2020.
- [8] S. Lautenbacher, M. Salinas-Ranneberg, O. Niebuhr, and M. Kunz, "Phonetic characteristics of vocalizations during pain," *Pain Reports*, vol. 2, no. 3, p. e597, 2017.
- [9] A. Gonzales, K. Yao, A. Vogel, and N. Egorova-Brumley, "What can speech tell us about pain?" *Pain Reports*, vol. 10, no. 4, p. e1293, 2025.
- [10] Y. Oshrat, A. Bloch, A. Lerner, A. Cohen, M. Avigal, and G. Zeilig, "Speech prosody as a biosignal for physical pain detection," in *Proceedings of Speech Prosody 2016*, 2016, pp. 420–424.
- [11] F. S. Tsai, Y. M. Weng, C. J. Ng, and C. C. Lee, "Embedding stacked bottleneck vocal features in an lstm architecture for automatic pain level classification during emergency triage," in *2017 Seventh International Conference on Affective Computing and Intelligent Interaction*. IEEE, 2017, pp. 313–318.
- [12] Z. Ren, N. Cummins, J. Han, S. Schnieder, J. Krajewski, and B. Schuller, "Evaluation of the pain level from speech: Introducing a novel pain database and benchmarks," in *Speech Communication; 13th ITG-Symposium*. VDE, 2018, pp. 1–5.
- [13] J. Williams, E. Schneiders, H. Card, T. Seabrooke, B. Pakenham-Walsh, T. Azim, L. Valls-Reed, G. Vigneswaran, J. R. Bautista, R. Chandra, and A. Farahi, "Predicting acute pain levels implicitly from vocal features," in *Proceedings of Interspeech 2024*, 2024, pp. 1460–1464.
- [14] T.-Q. Dao, E. Schneiders, J. Williams, J. R. Bautista, T. Seabrooke, G. Vigneswaran, R. Kolpekwar, R. Vashistha, and A. Farahi, "TAME Pain data release: using audio signals to characterize pain," *Scientific Data*, vol. 12, no. 1, p. 595, 2025.

- [15] S. Borna, C. R. Haider, K. C. Maita, R. A. Torres, F. R. Avila, J. P. Garcia, G. D. De Sario Velasquez, C. J. McLeod, C. J. Bruce, R. E. Carter, and A. J. Forte, "A review of voice-based pain detection in adults using artificial intelligence," *Bioengineering*, vol. 10, no. 4, p. 500, 2023.
- [16] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 5998–6008.
- [17] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, "Robust speech recognition via large-scale weak supervision," in *Proceedings of the 40th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 202. PMLR, 2023, pp. 28 492–28 518.
- [18] A. Baevski, Y. Zhou, A. Mohamed, and M. Auli, "wav2vec 2.0: A framework for self-supervised learning of speech representations," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 12 449–12 460.
- [19] N. Reimers and I. Gurevych, "Sentence-bert: Sentence embeddings using siamese bert-networks," in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 2019, pp. 3982–3992.
- [20] W. Wang, F. Wei, L. Dong, H. Bao, N. Yang, and M. Zhou, "Minilm: Deep self-attention distillation for task-agnostic compression of pre-trained transformers," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 5776–5788.
- [21] T. Baltrušaitis, C. Ahuja, and L.-P. Morency, "Multimodal machine learning: A survey and taxonomy," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 41, no. 2, pp. 423–443, 2019.
- [22] I. T. Jolliffe and J. Cadima, "Principal component analysis: a review and recent developments," *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, vol. 374, no. 2065, p. 20150202, 2016.
- [23] L. McInnes, J. Healy, N. Saul, and L. Großberger, "UMAP: Uniform manifold approximation and projection," *Journal of Open Source Software*, vol. 3, no. 29, p. 861, 2018.

- [24] J. B. MacQueen, "Some methods for classification and analysis of multivariate observations," in *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1. University of California Press, 1967, pp. 281–297.
- [25] J. H. W. Jr., "Hierarchical grouping to optimize an objective function," *Journal of the American Statistical Association*, vol. 58, no. 301, pp. 236–244, 1963.
- [26] L. McInnes, J. Healy, and S. Astels, "hdbscan: Hierarchical density based clustering," *Journal of Open Source Software*, vol. 2, no. 11, p. 205, 2017.
- [27] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.
- [28] L. Hubert and P. Arabie, "Comparing partitions," *Journal of Classification*, vol. 2, pp. 193–218, 1985.
- [29] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [30] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, pp. 785–794.
- [31] M. Ilse, J. M. Tomczak, and M. Welling, "Attention-based deep multiple instance learning," in *Proceedings of the 35th International Conference on Machine Learning*, ser. *Proceedings of Machine Learning Research*, vol. 80. PMLR, 2018, pp. 2127–2136.
- [32] S. Sheikh, J. Fishe, A. Norse, M. Henson, D. James, W. Sher, M. Lott, C. Kalynych, and P. Hendry, "Comparing pain intensity using the numeric rating scale and defense and veterans pain rating scale in patients revisiting the emergency department," *Cureus*, vol. 13, no. 8, p. e17501, 2021.
- [33] R. C. Serlin, T. R. Mendoza, Y. Nakamura, K. R. Edwards, and C. S. Cleeland, "When is cancer pain mild, moderate or severe? grading pain severity by its interference with function," *Pain*, vol. 61, no. 2, pp. 277–284, 1995.
- [34] Q. Shi, T. R. Mendoza, A. C. Dueck, H. Ma, J. Zhang, Y. Qian, D. Bhowmik, and C. S. Cleeland, "Determination of mild, moderate, and severe pain interference in patients with cancer," *Pain*, vol. 158, no. 6, pp. 1108–1112, 2017.

- [35] H. Bredin, R. Yin, J. M. Coria, G. Gelly, P. Korshunov, M. Lavechin, D. Fustes, H. Titeux, W. Bouaziz, and M.-P. Gill, “pyannote.audio: neural building blocks for speaker diarization,” in *2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2020, pp. 7124–7128.
- [36] B. McFee, C. Raffel, D. Liang, D. P. W. Ellis, M. McVicar, E. Battenberg, and O. Nieto, “librosa: Audio and music signal analysis in python,” in *Proceedings of the 14th Python in Science Conference*, 2015, pp. 18–24.
- [37] Y. Jadoul, B. Thompson, and B. de Boer, “Introducing parselmouth: A python interface to praat,” *Journal of Phonetics*, vol. 71, pp. 1–15, 2018.

Ringraziamenti

In primis, vorrei ringraziare il mio relatore, il **prof. Stefano Cirillo**, per avermi dato la possibilità di lavorare a questa tesi e di approfondire un argomento che mi ha toccata particolarmente da vicino. La perdita di mio padre, anch'egli paziente oncologico, ha reso questo lavoro ancora più significativo per me, permettendomi di affrontare lo studio con una sensibilità e una consapevolezza diverse. Forse, in fondo, non è stato un caso che proprio questo sia stato l'argomento che mi è stato proposto. Grazie per avermi permesso di trasformare un tema così doloroso in qualcosa che potesse dare un significato anche al mio percorso di studi.

Ringrazio il **dott. Giandomenico Solimando** per avermi dato quella spinta in più di cui avevo bisogno per affrontare l'ultimo esame, ricordandomi di essere meno in ansia e di credere maggiormente nelle mie capacità. Grazie per il sostegno e per le parole che, nei momenti giusti, hanno saputo darmi la carica per andare avanti.

Ringrazio il **dott. Raffaele Aurucci** per la sua disponibilità e per aver sempre saputo riconoscere e apprezzare il lavoro che stavo svolgendo. Il suo apprezzamento è stato per me una motivazione in più per continuare a credere in ciò che stavo studiando e nel percorso che avevo scelto. Grazie per essere stato, anche senza saperlo, la giusta carica nei momenti in cui ne avevo bisogno.

Ringrazio mia **mamma**, madre esemplare e donna dai grandi valori. Grazie per avermi insegnato cosa significhi fare i sacrifici per avermi insegnato a non arrendermi davanti a nessuna difficoltà e a rialzarmi sempre, anche quando la forza di andare avanti sembrava non esserci. Grazie per essere stata il mio rifugio nei momenti di totale sconforto, cercando sempre di sdrammatizzare e di strapparmi un sorriso. Grazie per le uscite in macchina a

cantare a squarciagola e per il meritato shopping. Grazie per tutti questi momenti, per la tua presenza e per tutto ciò che hai fatto per me. Te ne sarò sempre grata.

Ringrazio mia **sorella** Annapaola, grande donna ma eterna bambina. Grazie per le nostre chiacchierate davanti a pranzi veloci o in macchina, mentre mi riaccompagnavi a casa. Grazie per esserci stata sempre, nonostante la distanza che ci ha separato. Grazie per aver condiviso con me momenti semplici, ma che oggi custodisco tra i ricordi più belli.

Ringrazio il mio **fidanzato** Sabatino, per essere stato sempre la spalla su cui piangere e quella su cui sfogarmi. Grazie per avermi accompagnata ai miei ultimi esami e per esserti dovuto sobbire le mie ansie, le mie paranoie e i miei scleri per ogni esame che dovevo sostenere. Grazie per avermi sempre ripetuto: «Ce la farai, credo in te», nonostante i miei continui «Non ce la faccio più» e «Sono esausta». Grazie per avermi fatto credere un po' di più in me stessa, per avermi ricordato, nei momenti in cui lo dimenticavo, di cosa fossi capace e, soprattutto, per aver tirato fuori quella «cazzima» che, forse, nascondevo anche a me stessa.

Ringrazio **Sara**, collega universitaria e amica di questo estenuante percorso che ci ha fatte sclerare, piangere e ridere, ma che ci ha anche fatto crescere. Grazie per avermi accompagnata in questo percorso, per aver affrontato con me alcuni esami e per avermi dato consigli sui miei ultimi esami anche quando tu avevi già finito da un po'. Grazie per avermi tenuto la mano e per aver camminato al mio fianco, rendendo questo percorso un po' meno pesante e molto più bello da vivere.

Ringrazio **Gerardo**, collega e amico, per aver affrontato con me uno degli esami più tosti, in cui la professoressa ci ha fatto penare persino per riuscire a strappare un voto. Più che un esame, sembrava una vera e propria battaglia, in cui partivi già sapendo di avere poche possibilità di vittoria, perché si sa, una battaglia tra docente e studente è sempre vinta dal docente. Grazie per avermi aiutato con tutto il lavoro che c'era da fare: dagli assignment da consegnare prima delle scadenze, alle letture dei paper, al codice da scrivere e compilare, fino alla relazione da portare a termine.

Ringrazio **Camilla**, per avermi fatto staccare un po' la spina con le nostre chiacchiere, le passeggiate e i pranzetti a Salerno. Grazie per quei momenti di spensieratezza, per avermi regalato una pausa quando ne avevo bisogno e per tutte le risate condivise. Sono momenti semplici, ma che porterò sempre nel cuore.

Ringrazio **Paolo** che, nonostante non frequenti più l'università ha sempre trovato un modo per esserci: tra messaggini, chiacchiere e uscite a Salerno, quando riusciamo ad appararci. Grazie per esserci stato anche da lontano e per aver mantenuto vivo questo legame.

Infine, ma non per importanza, ringrazio **me stessa**, per essere riuscita a credere un po' di più nelle mie capacità e per avercela fatta, anche questa volta, nonostante tutto.

E voglio concludere con le parole di una canzone che mi ha accompagnata durante questo percorso universitario e che, più di tante altre, racchiude ciò che vorrei ricordare di questi anni:

«Fin quando tu c'ha faje, nun mullà maje
Pecché nun saje quanto sta luntano chello ca vulesse.»

— Tutto è possibile, Geolier feat. Pino Daniele